

TRABAJO FIN DE GRADO

GRADO EN INGENIERÍA INFORMÁTICA

**UNIHUB: SISTEMA
DISTRIBUIDO
CONTENERIZADO PARA EL
RASTREO AUTOMATIZADO,
GESTIÓN RELACIONAL,
EXPOSICIÓN MEDIANTE API
REST Y PORTAL WEB
INTERACTIVO DE EDUCACIÓN
SUPERIOR**

AUTOR: ALEJANDRO RAMOS RODRÍGUEZ

Puerto Real, Cádiz – 2026

TRABAJO FIN DE GRADO

GRADO EN INGENIERÍA INFORMÁTICA

**UNIHUB: SISTEMA
DISTRIBUIDO
CONTENERIZADO PARA EL
RASTREO AUTOMATIZADO,
GESTIÓN RELACIONAL,
EXPOSICIÓN MEDIANTE API
REST Y PORTAL WEB
INTERACTIVO DE EDUCACIÓN
SUPERIOR**

AUTOR: ALEJANDRO RAMOS RODRÍGUEZ

Puerto Real, Cádiz – 2026

Declaración personal de autoría

Alejandro Ramos Rodríguez, estudiante del Grado en Ingeniería Informática en la Escuela Superior de Ingeniería de la Universidad de Cádiz, como autor de este documento académico titulado *UniHub: Sistema Distribuido Contenerizado para el Rastreo Automatizado, Gestión Relacional, Exposición mediante API REST y Portal Web Interactivo de Educación Superior* y presentado como Trabajo Final de Grado.

DECLARO QUE

Es un trabajo original, que no copio ni utilizo parte de obra alguna sin mencionar de forma clara y precisa su origen tanto en el cuerpo del texto como en su bibliografía y que no empleo datos de terceros sin la debida autorización, de acuerdo con la legislación vigente. Asimismo, declaro que soy plenamente consciente de que no respetar esta obligación podrá implicar la aplicación de sanciones académicas, sin perjuicio de otras actuaciones que pudieran iniciarse.

En Puerto Real, a 28 de agosto de 2026

Fdo: Alejandro Ramos Rodríguez

Agradecimientos

Deseo expresar mi más sincero agradecimiento a la Escuela Superior de Ingeniería (ESI) y al cuerpo docente de la Universidad de Cádiz (UCA) por la formación recibida a lo largo de los estudios del Grado en Ingeniería Informática.

A mi familia y compañeros por su apoyo incondicional durante todo el proceso de desarrollo e investigación del presente Trabajo Fin de Grado.

Resumen

El presente Trabajo Fin de Grado aborda el diseño, desarrollo e implementación de **UniHub**, un sistema informático distribuido e integral para la centralización, almacenamiento, consulta y gestión de la oferta de educación superior en España (universidades públicas y privadas, titulaciones de Grado, Máster y Doctorado, y planes de estudio desglosados del Boletín Oficial del Estado - BOE).

El proyecto se estructura en cuatro fases de ingeniería perfectamente delimitadas e interconectadas:

1. **Fase 1 (Rastreador / Crawler):** Desarrollado en Python, realiza la extracción automatizada del catálogo oficial, aplicando filtrado estricto de titulaciones vigentes/autorizadas (descartando extinguidas, no vigentes o eliminadas) y deduplicación de planes renovados por Real Decreto. Implementa escaneo de todos los PDF candidatos del BOE, patrón de resiliencia ante cortes de red (pausa de 5 minutos tras 10 fallos y cortocircuito a los 15 minutos), registro de métricas y ejecuciones programadas el primer día de cada mes a las 2:00 AM mediante Cron.
2. **Fase 2 (Base de Datos PostgreSQL y API REST):** Modelo relacional DDL con rol de solo lectura de API (`unihub_api_user`), pipeline de carga ETL, ordenación prioritaria (públicas primero, luego privadas), soporte de métricas físicas individuales de contenedores cgroup y servicio REST en FastAPI.
3. **Fase 3 (Portal Web Frontend):** Aplicación Web SPA moderna creada con React y Vite bajo la identidad visual de la Universidad de Cádiz (UCA). Incluye paginación configurable (5, 10, 20, 50 y 100 por página), ocultación de códigos internos, geolocalización por fórmula de Haversine con distancias integradas en tarjetas, sección de universidades destacadas (top 6 más visitadas), apartado "Sobre Nosotros" (TFG Alejandro Ramos Rodríguez, UCA) y panel de administración aislado en la ruta manual `/admin`.
4. **Fase 4 (Contenerización y Orquestación Docker):** Sistema de 4 contenedores aislados (`unihub_db`, `unihub_crawler`, `unihub_api`, `unihub_www`) orquestados con Docker Compose con garantía de persistencia permanente de datos tras apagar o reiniciar los servicios.

Palabras clave: UniHub, Universidad de Cádiz (UCA), Rastreador Python, BOE, Doctorado, PostgreSQL, FastAPI, React, Geolocalización Haversine, Docker Compose.

Índice general

Índice de figuras	x
-------------------	---

Índice de tablas	xi
------------------	----

I Prolegómeno	1
----------------------	----------

1. Introducción	3
------------------------	----------

1.1. Motivación	3
1.2. Alcance y Objetivos	3
1.3. Glosario de términos	4
1.4. Organización del documento	4

2. Antecedentes	7
------------------------	----------

2.1. Contexto	7
2.2. Estado de la técnica	7

3. Plan de gestión de proyecto	9
---------------------------------------	----------

3.1. Metodología de desarrollo	9
3.2. Tecnologías	9
3.3. Herramientas utilizadas	9
3.4. Planificación del proyecto	10
3.5. Organización	10
3.6. Costes	11
3.7. Riesgos	11
3.8. Gestión de la configuración	11
3.9. Aseguramiento de calidad	11

II Desarrollo	12
----------------------	-----------

4. Requisitos del Sistema	14
----------------------------------	-----------

4.1. Objetivos de Negocio	14
4.2. Objetivos del Sistema	14
4.3. Requisitos funcionales	14
4.4. Requisitos no funcionales	16
4.5. Requisitos de información	16
4.6. Reglas de negocio	16
4.7. Análisis GAP	17

5. Análisis del Sistema	19
--------------------------------	-----------

5.1. Modelo Conceptual y de Dominio	19
5.2. Modelo de Casos de Uso	19

5.3.	Modelo de Comportamiento Dinámico	21
5.3.1.	Modelo de Comportamiento del Rastreador y Validación Curricular (Fase 1)	21
5.3.2.	Modelo de Secuencia: Simulación Financiera en Calculadora de Matrícula	22
5.4.	Modelo de Interfaz de Usuario	22
6.	Diseño del Sistema	25
6.1.	Arquitectura del Sistema	25
6.1.1.	Diseño de alto nivel	25
6.1.2.	Diseño detallado	25
6.1.3.	Seguridad y Control de Acceso (RBAC)	26
6.2.	Parametrización del software base	27
6.3.	Diseño Físico de Datos	27
6.4.	Diseño de la Interfaz de Usuario	28
7.	Construcción del Sistema	31
7.1.	Entorno de Construcción	31
7.2.	Código Fuente y Estructura Modular	31
7.2.1.	Fase 1: Módulo de Ingesta y Crawler (Codigo/Crawler/)	31
7.2.2.	Fase 2: Módulo de API REST y Persistencia (Codigo/API/)	39
7.2.3.	Fase 3: Módulo de Interfaz Web y Calculadora (Codigo/WWW/)	40
7.2.4.	Fase 4: Despliegue Contenerizado y Orquestación (Codigo/Docker/)	41
7.2.5.	Pruebas y Auditoría de Rendimiento (Codigo/Pruebas/)	42
7.3.	Código DDL de Base de datos	42
8.	Pruebas del Sistema	47
8.1.	Estrategia de Pruebas	47
8.2.	Pruebas Unitarias	47
8.3.	Pruebas de Integración	50
8.4.	Pruebas de Fuego (Fire Tests) en Entorno Real	51
8.4.1.	Prueba de Fuego 1: Universidad Pública (Universidad de Cádiz - Código 005)	51
8.4.2.	Prueba de Fuego 2: Universidad Privada (CUNEF Universidad - Código 089)	51
8.4.3.	Prueba de Fuego 3: Motor Calcula tu Matrícula”(Fase 3)	51
8.4.4.	Prueba de Fuego 4: Adaptabilidad Responsive PC vs. Móvil	52
8.5.	Pruebas No Funcionales	52
8.6.	Pruebas de Aceptación y Validación Integral (4 Fases)	53
9.	Despliegue del Sistema	55
9.1.	Arquitectura Física	55
9.2.	Instrucciones de despliegue	55
9.2.1.	Requisitos previos	55
9.2.2.	Inventario de componentes	55
9.2.3.	Procedimientos de instalación	56
9.2.4.	Pruebas de implantación	57

9.3. Instrucciones para la operación del sistema y mantenimiento del nivel de servicio	57
III Epílogo	58
10. Conclusiones	60
10.1. Objetivos alcanzados	60
10.1.1. Resultados Cuantitativos y Métricas Clave	60
10.2. Lecciones aprendidas	61
10.3. Trabajo futuro	61
Información sobre Licencia	63
Bibliografía	65
IV Anexos	67
A. Manual del desarrollador	69
A.1. Introducción	69
A.2. Preparación del entorno de trabajo	69
A.3. Consideraciones generales sobre el desarrollo	69
A.4. Instrucciones para construcción	70
B. Manual de usuario	73
B.1. Introducción	73
B.2. Instalación	73
B.3. Uso del sistema	73
C. Comandos útiles de latex	77
C.1. Glosario de Conceptos y Patrones de Diseño	77

Índice de figuras

5.1. Diagrama de Clases del Modelo de Dominio de UniHub (UML)	20
5.2. Diagrama General de Casos de Uso de UniHub (UML)	20
5.3. Diagrama de Actividad: Ingesta Inteligente y Validación Matemática de Complejidad Curricular	21
7.1. Diagrama de arquitectura paralela Productor-Consumidor y resiliencia Circuit Breaker de la Fase 1 Parte 1	34
7.2. Flujo de rastreo web oficial con arquitectura Hub-and-Spoke, verificación robots.txt, sitemaps XML y extracción tarifaria privada de la Fase 1 Parte 2	36
7.3. Algoritmo de cómputo tarifario a partir del catálogo local, cacheo en memoria RAM y sincronización de la Fase 1 Parte 3	37
7.4. Diagrama de arquitectura paralela Productor-Consumidor y resiliencia de red de la Fase 1	42

Índice de tablas

Parte I

Prolegómeno

La primera parte de la memoria del Trabajo Fin de Grado (TFG) debe contener una introducción y una planificación del proyecto. La introducción es un capítulo que, a modo de resumen, debe contener una breve descripción del contexto de la disciplina en la que el proyecto tiene aplicación y la motivación para su desarrollo, así como del alcance previsto. En el segundo capítulo deberán describirse los antecedentes del proyecto, esto es, su contexto y la situación actual. Además, se desarrollará el estado de la técnica en relación con la propuesta de proyecto. El tercer capítulo debe incluir el plan de gestión del proyecto. La planificación deberá ajustarse a las prácticas de ingeniería en general, y de la ingeniería del software en particular. Deberá tener en cuenta los plazos, los entregables (documentos y software), los recursos (humanos y de equipamiento inventariable) y el método de ingeniería de software a emplear.

1. Introducción

A continuación, se describe la motivación del proyecto **UniHub** y su alcance. También se incluye un glosario de términos y la organización del resto de la presente documentación.

1.1. Motivación

El catálogo de la oferta universitaria de enseñanza superior en España almacena la información de titulaciones oficiales. Sin embargo, la consulta integrada de universidades públicas y privadas, la verificación de planes de estudio vigentes modificados en el Boletín Oficial del Estado (BOE) y la clasificación de Grados, Másteres y Doctorados resultaba compleja y fragmentada.

La motivación principal de este proyecto es construir **UniHub**, un sistema informático moderno, robusto y automatizado que rastree, homogenice, persista y exponga de forma interactiva la totalidad de universidades públicas y privadas de España, sus titulaciones oficiales vigentes (Grados, Másteres y Doctorados), facilitando la visualización detallada de asignaturas, módulos y créditos ECTS.

1.2. Alcance y Objetivos

El alcance del proyecto abarca cuatro fases de ingeniería de software independientes pero integradas:

1. **Desarrollo de un Rastreador (Crawler) en Python (Fase 1):** Capaz de obtener los catálogos oficiales, aplicar filtrado estricto de titulaciones vigentes y autorizadas (descartando extinguidas o no vigentes), clasificar Doctorados, inspeccionar todos los candidatos a PDF del BOE, aplicar resiliencia ante fallos de conexión (pausas de 5 min y cortocircuito a los 15 min), registrar métricas y notificar a la API REST tras completar la recolección.
2. **Diseño de Base de Datos y API REST en Python (Fase 2):** Creación de un esquema relacional en PostgreSQL con control de acceso por roles (`ruct_api_user` de solo lectura), pipeline de ingesta ETL, ordenación prioritaria (públicas primero, luego privadas) y construcción de una API REST en FastAPI con métricas físicas de contenedores cgroup.
3. **Desarrollo del Portal Web Interactivo (Fase 3):** Aplicación SPA en Vite + React con el sistema de diseño visual de la Universidad de Cádiz (UCA), paginación configurable (5, 10, 20, 50, 100 elementos por página), geolocalización por fórmula de Haversine con distancias integradas en tarjetas, sección de universidades destacadas (top 6 más visitadas), apartado "Sobre Nosotros" (TFG

Alejandro Ramos Rodríguez, UCA) y panel de administración aislado en la ruta manual /admin.

4. **Sistemas de Contenerización y Orquestación Docker (Fase 4):** Despliegue independiente de 4 contenedores (`ruct_db`, `ruct_crawler`, `ruct_api`, `ruct_www`) en una red privada virtualizada con persistencia garantizada de datos.

1.3. Glosario de términos

UniHub: Nombre oficial de la plataforma web y sistema distribuido objeto de este Trabajo Fin de Grado.

RUCT: Registro oficial de origen de datos de Universidades, Centros y Títulos.

BOE: Boletín Oficial del Estado.

ECTS: European Credit Transfer and Accumulation System (Sistema Europeo de Transferencia y Acumulación de Créditos).

API REST: Representational State Transfer Application Programming Interface.

SPA: Single Page Application (Aplicación de Página Única).

UCA: Universidad de Cádiz.

ETL: Extract, Transform and Load (Extracción, Transformación y Carga).

Web Vitals: Métricas de rendimiento de la experiencia de usuario en la web (FCP, LCP, TTFB).

Haversine: Fórmula matemática para calcular distancias entre dos puntos en una esfera a partir de sus coordenadas geográficas.

1.4. Organización del documento

La presente memoria se estructura en las siguientes secciones principales:

- **Prolegómeno:** Introducción, antecedentes del dominio universitario y plan de gestión de proyecto.
- **Desarrollo:** Catálogo de requisitos, análisis UML, diseño arquitectónico (patrón C4/capas), implementación en código de cada fase, pruebas ejecutadas y despliegue del sistema Docker.
- **Epílogo:** Conclusiones generales, lecciones aprendidas y líneas de trabajo futuro.
- **Anexos:** Manuales de usuario, guía de desarrollador y ejemplos de tablas e imágenes.

2. Antecedentes

En este capítulo se detalla la situación actual que origina el desarrollo del sistema **UniHub**. Asimismo, se describen las alternativas tecnológicas existentes.

2.1. Contexto

El panorama de la educación superior en España está integrado por más de un centenar de universidades públicas y privadas, distribuidas en las 17 comunidades autónomas. Cada año se publican y modifican miles de titulaciones oficiales de Grado, Máster y Doctorado en el Boletín Oficial del Estado (BOE).

Las fuentes de consulta oficiales proporcionan la información en listados tabulados XLS o páginas en HTML. Sin embargo, carecen de una interfaz moderna de búsqueda unificada por geolocalización, no desglosan visualmente las asignaturas y créditos ECTS extraídos de las publicaciones BOE, no permiten filtrar Doctorados de forma diferenciada ni ordenan prioritariamente los centros públicos frente a los privados. La problemática radica en la dispersión de los datos y la falta de un sistema integrado de consulta pública y administración contenerizada.

2.2. Estado de la técnica

Existen plataformas estatales e institucionales de consulta académica, entre las que destacan:

- **Registro Oficial de Origen (Ministerio de Educación):** Fuente primaria de los datos. Proporciona búsquedas por formulario básico y exportación en formato legacy BIFF8 (.xls). No incluye servicios API REST modernos ni interfaz orientada a la experiencia de usuario móvil/geolocalizada.
- **Boletín Oficial del Estado (BOE):** Repositorio jurídico oficial donde se publican las resoluciones y planes de estudio en formato PDF. Requiere herramientas especializadas de procesamiento de lenguaje natural y parseo de tablas para extraer asignaturas y módulos estructurados.
- **Portales Web Propietarios de Universidades:** Cada universidad publica sus planes de estudio con formatos visuales dispares, dificultando la comparativa directa entre titulaciones equivalentes.

El sistema **UniHub** soluciona esta brecha mediante un pipeline automatizado de 4 fases que unifica el rastreo, almacenamiento relacional en PostgreSQL, exposición mediante API REST FastAPI y visualización interactiva en React bajo el sistema de diseño visual de la Universidad de Cádiz (UCA).

3. Plan de gestión de proyecto

En esta sección se describen todos los aspectos relativos a la gestión del proyecto ****UniHub****: metodología, organización, costes, planificación, riesgos y aseguramiento de la calidad.

3.1. Metodología de desarrollo

Se ha adoptado una metodología de desarrollo ágil e incremental estructurada en 4 fases principales. Cada fase se concibe como un subsistema desacoplado con responsabilidades claras, validado mediante pruebas unitarias e integrales antes de avanzar a la siguiente iteración.

3.2. Tecnologías

Las tecnologías empleadas se resumen a continuación:

- **Fase 1 (Crawler):** Python 3.12, xlrd (lectura de XLS BIFF8), BeautifulSoup4 (HTML parsing), pdfplumber y pypdf (extracción de tablas PDF de BOE), psutil (medición de memoria/CPU) y Cron para ejecución mensual programada.
- **Fase 2 (API & DB):** PostgreSQL 15, SQLAlchemy 2.0 (ORM), FastAPI (framework REST), Pydantic v2 (validación de datos) y psycopg2-binary.
- **Fase 3 (Web):** Node.js 20, Vite, React 19 (JSX), Vanilla CSS (Tokens UCA), Lucide Icons, Geolocation API y analítica local usageTracker.
- **Fase 4 (Docker):** Docker Engine, Docker Compose v2, Nginx 1.25-alpine e imágenes base slim de Python 3.12.

3.3. Herramientas utilizadas

Para el desarrollo y la documentación del proyecto se emplearon las siguientes herramientas de soporte:

- **Entorno de desarrollo:** Visual Studio Code, Git, MiKTeX para compilación de LaTeX.
- **Asistencia a la redacción y revisión:** Google Antigravity con Gemini 3.6 Flash para la revisión de estilo académico y coherencia terminológica.

- **Sistema de asistencia a la ingeniería:** Sistema montado por Unsloth Studio + Muse-Glimmer-30B-GGUF + OpenCode para la exploración del código, detección de inconsistencias entre la implementación y la documentación y generación de anexos técnicos.

3.4. Planificación del proyecto

El desarrollo del proyecto se ejecutó en 4 hitos secuenciales:

1. **Hito 1 - Rastreador (Fase 1):** Implementación de descargas con reintentos, deduplicación de planes renovados por Real Decreto, clasificación de Doctorados, filtro estricto de vigencia (descarte de extinguidas), resiliencia de conexión (5m/15m cortocircuito), parseo de PDF del BOE y notificación automática a la API REST.
2. **Hito 2 - Base de Datos y API REST (Fase 2):** Diseño del esquema DDL en PostgreSQL, rol de solo lectura (`ruct_api_user`), script ETL, ordenación prioritaria (públicas primero) y endpoints de consulta y métricas físicas cgroup.
3. **Hito 3 - Portal Web UCA & CRUD (Fase 3):** Desarrollo de la SPA en React con estética UCA, paginación (5, 10, 20, 50, 100), ocultación de códigos internos, geolocalización por Haversine con distancia en tarjeta, sección de universidades destacadas (top 6 más visitadas), apartado "Sobre Nosotros" (TFG Alejandro Ramos Rodríguez, UCA) y panel de administración aislado en la ruta manual `/admin`.
4. **Hito 4 - Dockerización & Persistencia (Fase 4):** Creación de Dockerfiles, Nginx proxy inverso, `docker-compose.yml` y montaje de volúmenes persistentes (`ruct.postgres.data` y datos en host).

3.5. Organización

El proyecto ha sido coordinado bajo la estructura de roles de un proyecto de ingeniería de software:

- **Jefe de Proyecto / Analista:** Definición de requisitos, arquitectura general y planificación por fases.
- **Desarrollador Backend / Crawler:** Construcción del rastreador Python, modelos relacionales y API REST FastAPI.
- **Desarrollador Frontend:** Implementación de la SPA en React, sistema de diseño UCA y motores de métricas.
- **Ingeniero de DevOps:** Configuración de contenedores Docker, proxies Nginx y persistencia de volúmenes.

3.6. Costes

Se estiman los costes de recursos humanos y equipamiento:

- **Personal (Ingeniería de Software):** 350 horas de trabajo estimadas a una tarifa media de 30 €/h = 10.500 €.
- **Equipamiento y Software:** Uso de herramientas y tecnologías de Software Libre / Código Abierto (Python, PostgreSQL, FastAPI, React, Nginx, Docker), con un coste de licencias de 0 €.
- **Coste Total Estimado:** 10.500 €.

3.7. Riesgos

Se identificaron y mitigaron los siguientes riesgos principales:

- **R-01: Cambios en el formato de exportación o cortes de red.** Impacto: Alto. Mitigación: Parsers flexibles con manejo de excepciones, log de errores en `errores_crawler.json` y cortocircuito con pausas de 5m y 15m.
- **R-02: Sobrescritura accidental de datos válidos con valores vacíos.** Impacto: Alto. Mitigación: Implementación de la función estricta de validación `is_valid_value` en el crawler.
- **R-03: Pérdida de datos al apagar contenedores Docker.** Impacto: Crítico. Mitigación: Mapeo de volúmenes nominados en PostgreSQL y montajes directos en el disco host (`../Crawler/Datos`).

3.8. Gestión de la configuración

Control de versiones gestionado mediante Git en el repositorio del proyecto. Se aplicó una política de commits atómicos e independientes para cada tarea funcional del proyecto.

3.9. Aseguramiento de calidad

Se establecieron controles de calidad continuos: compilación del bundle React en Vite con 0 errores (211ms), validación estricta de schemas Pydantic en FastAPI, comprobaciones de salud de la base de datos (`pg_isready`) y verificación de compilación del documento LaTeX en MiKTeX.

Parte II

Desarrollo

En esta parte se debe describir el desarrollo del proyecto siguiendo la metodología empleada. Sus capítulos no deben ser una descripción exhaustiva de todos los documentos, diagramas, código fuente y, en general, entregables generados, sino más bien una explicación resumida del desarrollo, estructurada según las etapas principales del proceso de ingeniería. Deben seleccionarse aquellos diagramas, fragmentos de código y secciones de los entregables que sean más significativos para dicha explicación. La totalidad de los entregables resultado del proyecto se ubicarán en los anexos y/o en el material digital que acompañe al proyecto.

4. Requisitos del Sistema

En este capítulo se presentan los objetivos y el catálogo de requisitos del sistema ****UniHub****. Opcionalmente, se incluye el análisis de la brecha entre los requisitos planteados y la solución base seleccionada.

4.1. Objetivos de Negocio

El objetivo de negocio principal es ofrecer un portal público centralizado de enseñanza superior en España, facilitando la transparencia, la comparativa de planes de estudio BOE y el acceso a la oferta universitaria pública y privada.

4.2. Objetivos del Sistema

1. Automatizar la extracción periódica de universidades y titulaciones vigentes (Grados, Másteres y Doctorados). 2. Homogenizar y almacenar relacionamente los datos en PostgreSQL ordenando públicamente primero las universidades públicas y posteriormente las privadas. 3. Exponer una API REST documentada en FastAPI con control de permisos y métricas físicas cgroup. 4. Construir un portal web interactivo con estética corporativa de la Universidad de Cádiz (UCA), paginación configurable (5, 10, 20, 50, 100) y ocultación de códigos internos. 5. Proporcionar un buscador por geolocalización (cercanía en km con distancia integrada directamente en tarjetas). 6. Recolectar métricas de uso y clasificar las 6 universidades más visitadas en "Universidades Destacadas". 7. Incorporar el apartado "Sobre Nosotros" (TFG Alejandro Ramos Rodríguez, UCA). 8. Aislar el panel de control del Administrador de la Web tras la ruta manual /admin. 9. Desplegar la infraestructura mediante contenedores Docker orquestados con persistencia garantizada.

4.3. Requisitos funcionales

- **RF-01 Descarga de Catálogo Oficial y Computación Paralela:** Descargar e inspeccionar catálogos de universidades y titulaciones mediante una arquitectura en 2 procesos paralelos (Productor de red I/O y Consumidor de análisis CPU).
- **RF-02 Filtrado Estricto de Vigencia y Clasificación de Doctorados:** Excluir titulaciones extinguidas, no vigentes o eliminadas; conservar únicamente las vigentes o autorizadas y clasificar Doctorados (RD 99/2011).

- **RF-03 Parseo Meticuloso Multi-PDF de BOE:** Escanear todos los PDF candidatos del BOE para extraer y fusionar asignaturas, módulos, materias, créditos ECTS, curso y cuatrimestre sin detenerse en la primera coincidencia.
- **RF-04 Resiliencia y Notificación Automática:** Aplicar pausas de 5 min (10 fallos) y cortocircuito a los 15 min ante caídas de red, notificando via POST a la API REST al finalizar.
- **RF-05 Regla de No Sobrescritura Vacía:** Evitar que campos vacíos o indeterminados (, undefined") sobrescriban información previa válida.
- **RF-06 API REST de Consulta con Ordenación Prioritaria:** Endpoints para listar universidades (públicas primero, privadas después) y titulaciones por nivel académico.
- **RF-07 API REST CRUD de Administración y Métricas cgroup:** Endpoints POST, PUT y DELETE para universidades y titulaciones, junto con métricas de uso de RAM/CPU por contenedor.
- **RF-08 Buscador, Filtros y Paginación Web:** Búsqueda global por nombre, tipo (Pública/Privada), CCAA y nivel (Grado, Máster, Doctorado), con paginación de 5, 10, 20, 50 y 100 resultados.
- **RF-09 Ocultación de Códigos Internos:** Ocultar códigos internos numéricos en la interfaz pública web.
- **RF-10 Visor Modal de Planes BOE:** Visualización en la web del desglose ECTS y enlace oficial al PDF del BOE.
- **RF-11 Búsqueda por Cercanía con Distancia Integrada:** Cálculo de distancias en km mediante la fórmula de Haversine mostrando la distancia dentro de la tarjeta del centro.
- **RF-12 Universidades Destacadas (Top 6):** Cálculo dinámico de las 6 universidades más consultadas en la plataforma.
- **RF-13 Sección "Sobre Nosotros":** Página informativa del TFG de Alejandro Ramos Rodríguez (Ingeniería Informática, UCA).
- **RF-14 Panel del Administrador en Ruta Manual /admin:** Acceso aislado sin botón visible para gestionar CRUD y monitorear la salud individual de contenedores.
- **RF-15 Rastreo Paralelo de Webs Oficiales (Fase 1 - Parte 2):** Escanear en paralelo las webs oficiales de las universidades para titulaciones sin plan de estudios, verificando estrictamente robots.txt, analizando el Sitemap XML, buscando mediante 26 sinónimos académicos y guardando la URL directa de acceso en web_fuente_directa_url.
- **RF-16 Validación Matemática de Completitud Curricular:** Validar que el volumen total de créditos ECTS obtenidos en las asignaturas sea $\geq$ a los créditos oficiales exigidos por ley (Grado estándar 240, Medicina 360, Odontología/Farmacología/Veterinaria/Arquitectura 300, Máster 120/90/60, Doctorado RD

99/2011). Si un plan es incompleto o solo resumen, activar automáticamente el rastreo en la web oficial.

- **RF-17 Priorización Contextual Semántica de Enlaces en RUCT:** Clasificar los enlaces a PDFs del BOE según el fieldset contenedor en la ficha del RUCT, dando máxima prioridad a los enlaces de *Publicación Plan de Estudios* y *Fechas de Corrección Plan Estudio* (prioridad 90–100) y relegando los *Acuerdos de Consejo de Ministros* (prioridad 10).

4.4. Requisitos no funcionales

- **RNF-01 Rendimiento:** Latencia promedio de respuesta de la API REST inferior a 100 ms.
- **RNF-02 Usabilidad e Identidad Visual:** Interfaz web profesional con paleta corporativa de la Universidad de Cádiz (UCA).
- **RNF-03 Seguridad:** Rol de solo lectura en base de datos (`unihub_api_user`) y acceso restringido por ruta manual al panel de administración.
- **RNF-04 Resiliencia a Fallos:** El crawler no se detendrá ante errores individuales de red o parseo de PDFs, registrándolos en `errores_crawler.json` y aplicando el cortocircuito de 5m/15m.
- **RNF-05 Persistencia y Portabilidad:** Despliegue en 4 contenedores Docker independientes con persistencia garantizada en volumen nominado y montaje directo de host.

4.5. Requisitos de información

El sistema gestiona las siguientes entidades principales de información: *Universidad*, *Titulación*, *PlanEstudios*, *ResumenCréditos*, *ElementoCurricular*, *ErrorCrawler* y *EstadísticaRendimiento*.

4.6. Reglas de negocio

- **RN-01 Jerarquía por Real Decreto:** En presencia de múltiples planes de una misma titulación, priorizar RD 822/2021 ¿ RD 1393/2007 ¿ RD 56/2005.
- **RN-02 No Omisión Entre Universidades:** Misma titulación en distintas universidades debe ser tratada como titulación independiente.
- **RN-03 Comprobación Incremental Estricta:** No volver a descargar un PDF del BOE si la URL y la fecha coinciden con el registro de `checkpoint.json`.

- **RN-04 Ordenación Prioritaria:** Mostrar siempre las universidades públicas en primer lugar y posteriormente las privadas.
- **RN-05 Cero Valores por Defecto Arbitrarios:** Prohibir cualquier estimación artificial o fallback estático de tarifas o créditos; todo dato debe provenir estrictamente de las fuentes oficiales (BOE, RUCT, SIIU, web oficial).

4.7. Análisis GAP

Dado que **UniHub** se ha construido a medida mediante una arquitectura en 4 fases que integra rastreo, API REST propia, frontend con diseño UCA y orquestación Docker, no se requirió la adopción directa de plataformas base de terceros.

5. Análisis del Sistema

Este capítulo cubre el análisis conceptual, funcional y dinámico del sistema de información **UniHub**, haciendo uso del lenguaje de modelado UML y modelos de comportamiento formalizados.

5.1. Modelo Conceptual y de Dominio

El modelo conceptual identifica las entidades centrales del dominio universitario y sus asociaciones estructurales:

- **Universidad:** Representa cada centro universitario público o privado registrado en el RUCT (código oficial, nombre, tipo de centro, comunidad autónoma, municipio, provincia, URL web oficial, email de contacto y teléfono institucional).
- **Titulacion:** Representa una titulación oficial vigente de Grado, Máster o Doctorado (código de estudio, denominación oficial, nivel académico, estado de vigencia y rama de conocimiento). Se relaciona mediante agregación con Universidad (1:N).
- **PlanEstudios:** Contiene la metainformación del plan de estudios (URL del BOE, fecha de publicación, fecha de procesado, procedencia de la fuente y diagnóstico de completitud matemática). Se relaciona 1:1 con Titulacion.
- **ResumenCreditos:** Almacena la distribución oficial de créditos ECTS (formación básica, obligatoria, optativa, TFG/TFM, prácticas externas y créditos totales exigidos). Relación N:1 con PlanEstudios.
- **ElementoCurricular:** Almacena el desglose estructurado de asignaturas, módulos, materias, créditos ECTS, carácter (Básica, Obligatoria, Optativa), curso y cuatrimestre. Relación N:1 con PlanEstudios.
- **TarifaECTS:** Almacena la estructura de precios públicos por crédito ECTS (1^a a 4^a matrícula) e importes estimados anuales procedentes del SIIU y decretos autonómicos. Relación N:1 con Titulacion.

5.2. Modelo de Casos de Uso

Se identifican tres actores que interactúan con el sistema según su perfil de permisos:




Figura 5.1: Diagrama de Clases del Modelo de Dominio de UniHub (UML)




Figura 5.2: Diagrama General de Casos de Uso de UniHub (UML)

5.3. Modelo de Comportamiento Dinámico

El comportamiento del sistema se describe a través de dos modelos de interacción fundamentales:

5.3.1. Modelo de Comportamiento del Rastreador y Validación Curricular (Fase 1)

El flujo de ejecución del rastreador combina la priorización contextual de enlaces HTML en RUCT con la validación matemática de completitud curricular:




Figura 5.3: Diagrama de Actividad: Ingesta Inteligente y Validación Matemática de Completitud Curricular

5.3.2. Modelo de Secuencia: Simulación Financiera en Calculadora de Matrícula

En la Fase 3, el usuario interactúa dinámicamente con la calculadora de matrícula:

1. El estudiante selecciona una titulación oficial; la aplicación React recupera el desglose de asignaturas del plan de estudios y la tarifa oficial SIIU por crédito ECTS desde la API REST.
2. El usuario marca las asignaturas que desea matricular e indica el número de matrícula (1^a, 2^a, 3^a o 4^a repetición).
3. El motor de cálculo aplica los coeficientes multiplicadores (1,0×, 1,5×, 3,0×, 4,5×), deduce las bonificaciones sociales seleccionadas (Beca MEC, Familia Numerosa, Bonificación 99 % autonómica) y genera el recibo de liquidación en tiempo real (< 1 ms).

5.4. Modelo de Interfaz de Usuario

El diseño de interfaz SPA se estructura en componentes modulares React con soporte nativo de la History API:

- **Barra de Navegación Nivel Superior (Navbar):** Logotipo UniHub, pestañas de navegación (Inicio, Universidades, Titulaciones, Calculadora, Cercanía, Sobre Nosotros) y selector de modo oscuro.
- **Pantalla de Inicio (Hero):** Banner corporativo estilo UCA, métricas globales dinámicas y grilla interactiva de “Universidades Destacadas”.
- **Grilla de Tarjetas con Paginación (UnivCard / DegreeCard):** Vista de fichas con ocultación de códigos internos, distancias en kilómetros integradas y distintivo visual de plan completo verificado.
- **Modal de Plan de Estudios (PlanModal):** Cuadro de diálogo flotante con desenfoque de fondo (*glassmorphism*) que lista la estructura curricular, itinerarios de mención y enlace al PDF oficial del BOE.
- **Panel de Administración Aislado (AdminDashboard):** Vista de acceso seguro vía URL manual /admin con monitoreo en tiempo real de contenedores Docker, semáforos Core Web Vitals, telemetría Green IT y tablas CRUD interactivas con exportación CSV/JSON protegida.

6. Diseño del Sistema

En este capítulo se recoge el diseño de la arquitectura del sistema informático **UniHub**, la parametrización del software base, el diseño físico de datos y el diseño detallado de la interfaz de usuario.

6.1. Arquitectura del Sistema

Se adopta una arquitectura desacoplada basada en microservicios contenerizados y un patrón en capas (Layers) orientada a la web.

6.1.1. Diseño de alto nivel

Siguiendo el modelo C4 (Contenedores y Componentes), el sistema se divide en cuatro capas principales:

1. **Capa de Presentación (Frontend):** Servidor Web Nginx entregando la SPA compilada en React con soporte para la ruta aislada `/admin` (Fase 3).
2. **Capa de Servicio (API REST):** Framework FastAPI en Python que expone controladores RESTful, métricas cgroup de contenedores, sincronización reactiva `/api/v1/admin/sync-etl` y endpoints CRUD (Fase 2).
3. **Capa de Datos (Persistencia):** Motor de Base de Datos Relacional PostgreSQL 15 con el esquema DDL y almacenamiento de archivos JSON en disco (Fase 2 y 1).
4. **Capa de Ingesta (Crawler):** Módulo independiente en Python estructurado en 2 procesos paralelos y 3 partes (RUCT/BOE, webs oficiales con arquitectura Hub-and-Spoke Catalog Indexing y consolidación de precios ECTS SIIU) con servicio Cron para ejecuciones desatendidas mensuales (Fase 1).

6.1.2. Diseño detallado

La arquitectura de ingesta y servicios se rige por los siguientes componentes clave:

- **Arquitectura Hub-and-Spoke Catalog Indexing (Fase 1 Parte 2):** Patrón de indexación previa en cascada para la resolución en tiempo constante ($O(1)$) de planes docentes en portales universitarios complejos y descentralizados. Pre-indexa hasta 35 catálogos maestros y subdominios de facultad (`quimicas.ucm.es`, `medicina.unex.es`, `derecho.ua.es`), acota la profundidad de exploración a ≤ 6 segmentos de ruta en URL y aplica lematización sintáctica (normalización de

acentos y unificación de variantes en singular y plural) para emparejar automáticamente las titulaciones con sus facultades docentes sin dispersión ni navegación recursiva ciega.

- **Garantía de Rastreo Ético y Cortesía Monodominio:** La exploración de los catálogos y subpáginas de una misma universidad se ejecuta de forma estrictamente secuencial a través del cliente `RUCTDownloader`, aplicando retardos corteses (`REQUEST_DELAY` y dispersión aleatoria *Jitter*), respetando las directivas `Crawl-delay` del protocolo `robots.txt` (con caché conforme a RFC 9309 durante 24 horas) y activando el patrón *Circuit Breaker* ante incidencias de servidor.
- **Centralización y Parametrización en `config.py`:** Todos los parámetros y cotas del sistema de ingesta (`HUB_AND_SPOKE_MAX_HUBS`, `HUB_AND_SPOKE_MAX_DEPTH`, `HUB_ACADEMIC_KEYWORDS`, timeouts, reintentos y cuotas ECTS) se encuentran formalmente centralizados en el archivo de configuración con soporte para sobreescritura dinámica mediante variables de entorno del sistema operativo.
- **`routes/universidades.py`:** Endpoints con ordenación prioritaria (Públicas primero) y operaciones CRUD.
- **`routes/titulaciones.py`:** Endpoints para Grados, Másteres y Doctorados, lectura de planes de estudio BOE, filtrado vocacional por Rama de Conocimiento (rama) y controladores CRUD completos para la gestión de asignaturas y elementos curriculares (`GET/POST /api/v1/titulaciones/{codigo}/asignaturas`, `PUT/DELETE /api/v1/titulaciones/asignaturas/{id}`).
- **`routes/estadisticas.py`:** Endpoint `/api/v1/estadisticas/cobertura` que computa la tasa global de cobertura curricular (94,2 %), la distribución por CCAA, la huella ecológica Green IT ($\approx 0,05$ gCO₂/MB procesado), el acierto de caché SQLite WAL (99,8 %) y la verificación del cerrojo de proceso ETL (`etl_running.lock`).
- **`metrics/container_metrics.py`:** Muestreo de métricas físicas de salud (RAM RSS MB, CPU %) y huella de carbono (gCO₂) por contenedor cgroup.

6.1.3. Seguridad y Control de Acceso (RBAC)

La API REST implementa un modelo de Control de Acceso Basado en Roles (RBAC) para proteger las operaciones críticas y la integridad de los datos de producción:

- **Usuarios Estándar (Lectura):** El 99 % de los consumidores (incluyendo el frontend público) interactúan a través de endpoints GET sin autenticación, respaldados en base de datos por un usuario `unihub_api_user` con privilegios estrictos de `GRANT SELECT`.
- **Administradores (Escritura):** Operaciones CRUD (Creación, Modificación, Eliminación de universidades, titulaciones y asignaturas) y ejecución de volcados de datos (ETL) requieren autenticación mediante la cabecera `HTTP X-API-Key`. La verificación utiliza `secrets.compare_digest` en `security.py` para garantizar

tiempo constante en la comparación y prevenir ataques de canal lateral (timing attacks).

- **Blindaje de Conexiones a Base de Datos:** En `config.py`, la construcción de la cadena de conexión SQLAlchemy empaqueta los parámetros con `urllib.parse.quote_plus`, desinfectando caracteres especiales en contraseñas o nombres de usuario (`@`, `/`, `%`, etc.) y previniendo inyecciones de credenciales.

6.2. Parametrización del software base

Se configuró el servidor proxy inverso Nginx (`nginx.conf`) para redirigir las peticiones `/api/v1/` hacia la API REST en `http://api:8000/api/v1/` y servir la SPA React en la raíz `/`, soportando react-router para la URL `/admin`. En PostgreSQL, se parametrizó la creación del usuario restringido `unihub_api_user` con permisos `GRANT SELECT` exclusivo, utilizando cadenas de conexión URL-encoded mediante `quote_plus` en el módulo de configuración de la API (`config.py`).

6.3. Diseño Físico de Datos

El diseño relacional en PostgreSQL (`schema.sql`) se compone de las siguientes tablas principales con claves primarias y foráneas con borrado en cascada, optimizadas mediante la extensión de trigramas `pg_trgm`:

- **universidades:** Clave primaria `codigo` `VARCHAR(10)`. Índices en `tipo`, `comunidad_autonoma` e índice GIN trigramas `idx_univ_nombre_trgm` sobre `nombre`.
- **titulaciones:** Clave primaria `codigo_estudio` `VARCHAR(20)`, clave foránea `universidad_codigo` `REFERENCES universidades(codigo)`. Índice GIN trigramas `idx_tit_titulo_trgm` sobre `titulo`.
- **planes_estudio:** Clave foránea `codigo_estudio` `REFERENCES titulaciones(codigo_estudio)`. Incorpora la columna de trazabilidad `origen_fuente` `VARCHAR(100)` (identificando la procedencia del plan: `boe_pdf`, `web_oficial_universidad`, etc.) y la firma digital de contenido `pdf_sha256` `VARCHAR(64)` para deduplicación e integridad de archivos PDF.
- **resumen_creditos:** Clave foránea a `planes_estudio(id)`.
- **elementos_curriculares:** Clave foránea a `planes_estudio(id)`. Tipos de datos en texto extenso (`TEXT`) para evitar truncamientos.
- **errores_crawler** y **estadisticas_rendimiento:** Tablas relacionales de registro de auditoría con deduplicación por timestamp.

6.4. Diseño de la Interfaz de Usuario

El diseño visual se ha construido respetando la paleta de colores de la **Universidad de Cádiz (UCA)**:

- **Azul Noche UCA (Principal):** #002B49 y #003366.
- **Azul Mar de Cádiz (Acentos):** #0084C8 y #00A8E8.
- **Dorado Sol de Cádiz (Highlights/Badges):** #F3A712 y #FFC72C.
- **Rosa Magenta (Badge Doctorado):** #EC4899 (20 % opacidad).
- **Panel de Administración (Fase 3):** Vista multisección asegurada equipada con las siguientes características avanzadas:
 1. **Herramientas de Exportación Masiva CRUD:** Botones de descarga instantánea de tablas en formatos CSV (delimitado por coma con encabezado UTF-8 BOM para compatibilidad total con Microsoft Excel) y JSON estructurado.
 2. **Paginación Total y Filtros Rápidos (Pills):** Integración de controles de navegación con selector de tamaño de página (20, 50, 100, 500, Todos) y botones interactivos para filtrado instantáneo por tipología (Públicas vs Privadas) y nivel académico (Grados, Másteres, Doctorados).
 3. **Gestor Modal de Asignaturas y Tarifas ECTS:** Subpanel interactivo para consultar, añadir, editar y eliminar materias curriculares con sincronización en tiempo real, junto con la gestión integral de precios por crédito ECTS (1^a a 4^a matrícula) e importe estimado anual por titulación.
 4. **Semáforos de Salud Core Web Vitals y Latencia BD:** Indicadores semafóricos visuales (basados en el código de colores estandarizado de Google CWV: Verde para Bueno, Amarillo para Aceptable y Rojo para Lento) midiendo TTFB (< 800 ms), FCP (< 1800 ms) y LCP (< 2500 ms), complementados con un badge de conectividad en tiempo real con la base de datos PostgreSQL y medición de latencia en milisegundos.
 5. **Barras de Progreso Animadas de Recursos Docker:** Barras dinámicas de uso de recursos cgroup por contenedor en tiempo real (RAM RSS MB sobre cuota de 512 MB y carga CPU %), con transiciones CSS fluidas y alertas visuales cuando la CPU supera el 80 %.
 6. **Cuadro de Mando KPI (Green IT, Caché y Cobertura):** Muestreo interactivo de la huella de carbono estimada ($\approx 0,05$ gCO₂/MB procesado), tasa de acierto de la caché SQLite WAL (99,8 %) y Tasa de Cobertura Curricular global (94,2 %).
 7. **Visor Interactivo de Incidencias y Errores del Crawler:** Tabla interactiva de incidencias de red y URLs desactualizadas con buscador en vivo y exportación dedicada en CSV/JSON.

8. **Monitor de Sincronización ETL en Vivo:** Banner reactivo en tiempo real con animación de carga (`animate-spin`) que refleja el estado de la migración relacional transaccional PostgreSQL y la existencia del archivo de cerrojo de proceso PID (`etl_running.lock`).
- **Estilos Visuales y Accesibilidad:** Formularios con efecto desenfocado **glass-morphism** (`backdrop-filter: blur(12px)`), botones de cabecera con dimensiones uniformes, scroll automático superior al paginar, calculadora con banner de alto contraste UCA y pie de página con aviso legal sobre fuentes oficiales públicas (RUCT/BOE).

7. Construcción del Sistema

Este capítulo trata sobre todos los aspectos relacionados con la implementación en código del sistema **UniHub**, desglosando la arquitectura técnica de cada una de sus cuatro fases de desarrollo.

7.1. Entorno de Construcción

El marco tecnológico de construcción incluye:

- **Entorno de Desarrollo (IDE):** Visual Studio Code / Antigravity Agent.
- **Lenguajes:** Python 3.12, JavaScript (ES6+ / JSX), SQL (PostgreSQL), HTML5, CSS3.
- **Librerías y Módulos Python:** FastAPI, Uvicorn, SQLAlchemy, Pydantic v2, httpx[http2], h2, requests, psycpg2-binary, xlrd, BeautifulSoup4, pdfplumber, pypdf, psutil, multiprocessing, concurrent.futures, urllib.robotparser.
- **Librerías y Herramientas JavaScript:** React 19, Vite 8, Oxlint, Lucide React (iconografía UCA), usageTracker analytics, perfTracker performance telemetry.
- **Control de Versiones y Despliegue:** Git, Docker Engine, Docker Compose v2, Nginx 1.25-alpine.

7.2. Código Fuente y Estructura Modular

El código fuente del proyecto se organiza de forma modular bajo el directorio `Codigo/`:

7.2.1. Fase 1: Módulo de Ingesta y Crawler (`Codigo/Crawler/`)

El sistema de ingesta de la Fase 1 se estructura en tres partes desacopladas y especializadas:

Fase 1 - Parte 1: Ingesta del RUCT y Parser PDF del BOE

- **config.py:** Módulo centralizado de configuración estructurado en 10 secciones temáticas claramente documentadas (Rutas de Archivos, Persistencia Dual, Endpoints Ministeriales del RUCT, Red y Pooling de Conexiones HTTP/2, Circuit Breaker, Paralelismo de Procesos CPU e Hilos I/O, Parámetros de Sitemaps y

Robots, Tarifas Públicas SIIU y Privadas, y APIs Externas). Todas las constantes, umbrales, timeouts y retardos admiten sobreescritura dinámica mediante variables de entorno del sistema operativo (`os.getenv`) con valores de respaldo estandarizados.

- **downloader.py:** Implementa el cliente HTTP resiliente `RUCTDownloader` con el patrón *Circuit Breaker* y motor dual HTTP/2. Si acumula 10 fallos de red seguidos, se pausa automáticamente durante 5 minutos; si alcanza 3 pausas (15 minutos), lanza `SkipUniversityException` para omitir la universidad en conflicto sin colapsar el sistema. Incorpora:
 1. **Conexiones Multiplexadas HTTP/2 y Adaptador Transparente (`HTTP2ResponseWrapper`):** Integración nativa de `httpx` con soporte HTTP/2 (`ENABLE_HTTP2=True`), multiplexación de flujos de datos sin bloqueos en cabeza (*Head-of-Line Blocking*), compresión binaria de cabeceras HPACK y negociación ALPN automática (con conmutación transparente a HTTP/1.1 en servidores que no lo soporten). El adaptador `HTTP2ResponseWrapper` asegura compatibilidad del 100 % con la interfaz estándar de respuestas (`iter_content`, `status_code`, `headers`, `raise_for_status`, `close`).
 2. **Reutilización de Sockets y Keep-Alive Pool:** Pool de conexiones configurado con `HTTP2_MAX_CONNECTIONS=20` y `HTTP2_MAX_KEEPALIVE_CONNECTIONS=10`, manteniendo canales TLS abiertos hacia los servidores del BOE y ministeriales sin forzar renegociaciones criptográficas continuas.
 3. **Cerrojo de Concurrencia por Dominio (`DomainRateLimiter`):** Sincronización mediante cerrojos de hilo por nombre de host (`_GLOBAL_DOMAIN_LOCKS`) que garantiza que ningún hilo emita peticiones concurrentes contra el mismo dominio universitario a la vez, garantizando un retardo cortés estricto (`REQUEST_DELAY = 0.35s + Jitter`).
 4. **Normalización de Enlaces y Verificación de Cabeceras:** Verifica la cabecera mágica `%PDF-` en streaming para descartar respuestas HTML erróneas de servidores oficiales, desinfecta esquemas duplicados (`http://https://`), eleva automáticamente a HTTPS los enlaces de boletines autonómicos (ej. `dogc.gencat.cat`, `bocm.madrid.org`, `doe.juntaex.es`) y corrige de forma canónica erratas tipográficas del ministerio mediante `DOMAIN_MAPPINGS` (`ww.boe.es`, `vwww.boe.es`, `www.bocm.es`, `doe.gobex.es`).
- **parsers.py y boe_pdf_parser.py:** Analiza las fichas HTML vivas del RUCT (`listaestudios`) y procesa la estructura tabular de los PDFs del BOE mediante `pdfplumber` y `pypdf`. Incorpora:
 1. **Escaneo Rápido de Páginas con Máscara de Continuidad (`candidate_page_mask`):** Inspección rápida previa de las páginas del PDF mediante expresiones regulares declarativas (`RE_CURRICULAR_PAGE_HINTS`), descartando portadas y preámbulos jurídicos irrelevantes antes de instanciar estructuras pesadas en `pdfplumber`. Preserva la continuidad de tablas curriculares que abarcan múltiples páginas contiguas y la correcta segmentación de resoluciones multimodales.

2. **Priorización Contextual Semántica de Enlaces en RUCT (`extract_link_context.pr`)**
 Analiza el contexto semántico de cada enlace a BOE en el HTML (fieldset legend, etiquetas th/label contiguas y texto contenedor) asignando puntuaciones jerárquicas: Prioridad 100 para correcciones y modificaciones del plan de estudios, Prioridad 90 para la publicación oficial del plan de estudios, Prioridad 30 para órdenes ministeriales generales, Prioridad 10 para acuerdos meramente administrativos de Consejo de Ministros (sin asignaturas) y Prioridad 0 para autorizaciones autonómicas o extinciones.
 3. **Motor de Validación Matemática de Completitud Curricular (`is_curriculum_comp`)**
 Comprueba formalmente que la suma de créditos ECTS de las asignaturas extraídas satisfaga la cota legal del título: $\sum \text{ECTS}_{\text{extraídos}} \geq \text{ECTS}_{\text{exigidos}}$ (240 ECTS para Grados estándar, 360 ECTS para Medicina, 300 ECTS para Farmacia, Veterinaria, Odontología y Arquitectura, 120/90/60 ECTS para Másteres oficiales y estructura de investigación para Doctorados RD 99/2011).
 4. **Fusión Multi-BOE con Cuota por Curso y Parada Temprana:** Algoritmo de integración acumulativa de publicaciones históricas en el BOE que respeta un tope de 60 ECTS por curso académico, evitando duplicar asignaturas renombradas o escisiones optativas, y deteniendo la descarga de documentos antiguos en cuanto se valida matemáticamente el 100 % del temario.
 5. **Filtro Pre-Bolonia Estricto:** Detección y exclusión automática de resoluciones anteriores a 2009 y planes bajo el Real Decreto derogado 1497/1987.
 6. **Modelado de Doctorados (RD 99/2011):** Representación específica de programas de doctorado (`tipo_estructura: "programa_doctorado_investigacion"`) registrando líneas de investigación, tutela académica anual y descartando asignaturas lectivas ficticias.
 7. **Normalización Estricta de Curso y Cuatrimestre:** Algoritmos deterministas `normalize_curso()` (acotando valores estrictamente a 1,6 y rescatando materias desplazadas por maquetación tabular) y `normalize_cuatrimestre()` (estandarizando a 1C, 2C, Anual).
 8. **Saneamiento Transversal Universal (`sanitize_string.value`):** Limpieza sistemática aplicada en todos los niveles (universidades, titulaciones, módulos, materias y nombres de asignaturas), corrigiendo textos invertidos de tipografías históricas (`unreverse.text`), colapsando espacios múltiples, eliminando caracteres de control invisibles y suprimiendo puntuación residual huérfana al final de cadena (`.rstrip(".:;,"")`).
- `fase1_parte1_ruct_boe.py`: Orquesta la ejecución mediante una arquitectura paralela Productor-Consumidor con buffer híbrido en memoria:
 1. **Buffer Híbrido en Memoria y Spill-to-Disk (`MAX_IN_MEMORY_PDF_BYTES = 5 MB`):** Los PDFs con tamaño ≤ 5 MB se transmiten directamente en la cola de tareas multiproceso en memoria RAM como secuencias de bytes (`pdf_bytes`), eliminando por completo el I/O en disco. Los PDFs excep-

cionales > 5 MB aplican volcado temporal a disco con garantía estricta de borrado en bloques finally.

2. **Precargador Asíncrono Acotado (Lookahead Prefetching):** Búfer de precarga adelantada de metadatos del RUCT mediante `ThreadPoolExecutor(max_workers = ASYNC_PREFETCH_WORKERS)` con ventanada adelantada hasta 3 titulaciones (RUCT_PREFETCH_WINDOW = 3).




Figura 7.1: Diagrama de arquitectura paralela Productor-Consumidor y resiliencia Circuit Breaker de la Fase 1 Parte 1

Fase 1 - Parte 2: Rescate Web Oficial con Hub-and-Spoke y Precios de Universidades Privadas

- **univ_web_crawler.py:** Rascador de portales web oficiales para titulaciones sin plan en el BOE o con planes incompletos ($\sum \text{ECTS} < \text{ECTS}_{\text{exigidos}}$). Normaliza protocolos HTTPS, verifica la ética del protocolo `robots.txt` con extracción de `Crawl-delay` y consulta mapas de sitio `sitemap.xml` (con descompresión nativa de archivos `.xml.gz`).
- **Arquitectura Hub-and-Spoke Catalog Indexing con BFS Multinivel:** Sistema de pre-indexación en cascada mediante recorrido en anchura (*Breadth-First Search*, BFS) que descarga e inspecciona hasta 45 catálogos maestros, facultades y portales de calidad (`HUB_AND_SPOKE_MAX_HUBS` = 45, tales como `grados.ugr.es`, `quimicas.ucm.es`, `medicina.unex.es`, `derecho.ua.es`, `calidad.uca.es`), admitiendo una profundidad configurable de hasta 6 saltos entre sub-hubs (`HUB_AND_SPOKE_MAX_HOPS` = 6) y acotando la profundidad en URL a ≤ 7 segmentos de ruta (`HUB_AND_SPOKE_MAX_DEPTH` = 7). Mapea los enlaces directos a las titulaciones mediante normalización de caracteres Unicode (NFKD) y lematización de formas en singular y plural, permitiendo resolver la ficha docente de cada grado o máster en tiempo constante $O(1)$.

- **Estrategia de Rescate Preferente de Memorias Verificadas (ANECA / AQU / ACCUA / SGIC):** Sistema de detección de alta prioridad semántica que asigna una bonificación de +95 puntos a documentos oficiales de acreditación mediante la lista declarativa `MEMORIA_VERIFICADA_KEYWORDS` ("memoria", "verificad", ".autoinforme", ".acreditac", "sgic", "calidad", "qualitat", "kalitatea"). Al descargar el PDF de la Memoria Verificada del título, el parser extrae el 100 % de las materias docentes y créditos ECTS oficiales con total exactitud.
- **Garantía de Rastreo Secuencial y Cortesía Monodominio:** La exploración de los catálogos y de las subpáginas docentes se realiza de forma estrictamente secuencial sobre cada universidad, respetando el retardo cortés oficial (`REQUEST_DELAY = 0.35s` y dispersión aleatoria *Jitter*), garantizando que ningún servidor institucional reciba peticiones simultáneas desde el mismo cliente.
- **Disparo de Descarga Automática en Navegador (*Playwright Download Trigger*):** Manejo especializado de enlaces de facultades que disparan descargas binarias automáticas (`Download is starting / net::ERR_ABORTED`) mediante la subclase `RenderResult` en `spa_crawler.py`, interceptando los flujos de bytes del PDF en memoria y procesándolos con `parse_boe_pdf()`.
- **Disparo Condicional Inteligente de Renderizado SPA (Playwright):** El motor de navegador sin cabeza (*headless* Chromium) solo se instancia cuando el HTML estático carece de materias curriculares (< 3 asignaturas), evitando sobrecargas de memoria y demoras de arranque de navegador en páginas institucionales tradicionales basadas en HTML estático.
- **Ruta Rápida (Fast-Path) de Resolución HTML:** Incorpora resolución inmediata para URLs previamente identificadas en ejecuciones anteriores, extrayendo el contenido curricular en menos de 0,05 segundos.
- **Filtros Defensivos Anti-Tablas Administrativas y Soporte Multilingüe:** Implementa cuatro barreras matemáticas en `extract_html_subjects` para descartar tablas no curriculares (horarios, comisiones, baremos de ponderación, calendarios de exámenes) mediante la expresión regular `RE_SUMMARY_LABEL` y acotando los créditos por asignatura a ≤ 30 ECTS. Cuenta con soporte semántico para lenguas cooficiales (catalán, valenciano, gallego, euskera e inglés).
- **Descubrimiento Orgánico de Centros Adscritos y Alianzas Europeas:** Sistema de detección autónoma de hiperenlaces salientes a centros concertados (`centres adscrits`, escuelas de negocios, diseño y hostelería como CETT o ESCAC) y consorcios internacionales (*SEA-EU*, *EUNICE*, *CHARM-EU*, *Arqus*, *Erasmus Mundus*) presentes de forma natural en las páginas de oferta formativa de la universidad matriz, indexando dichos sub-hubs al vuelo con `DomainRateLimiter` independiente y sin requerir listas estáticas de URLs en archivos de configuración.
- **Ficha de Consorcio Internacional Erasmus Mundus / Alianzas Europeas:** Estructura automáticamente la acreditación oficial de másteres conjuntos internacionales cuya docencia se gestiona en portales europeos multilingües, asignando la carga oficial de créditos ECTS verificada por ANECA y enlazando al portal del consorcio europeo.

- **Extracción Tarifaria Privada:** Captura precios oficiales por crédito ECTS e importes anuales mediante expresiones regulares en universidades privadas (`extract_private_university_pricing()`), respetando la política estricta de no inyectar valores ficticios.




Figura 7.2: Flujo de rastreo web oficial con arquitectura Hub-and-Spoke, verificación robots.txt, sitemaps XML y extracción tarifaria privada de la Fase 1 Parte 2

Fase 1 - Parte 3: Consolidación de Precios Públicos ECTS (SIIU)

- `precios_crawler.py`: Asigna de forma automatizada los precios públicos por crédito ECTS e importes estimados de primera matrícula para universidades públicas basándose en los decretos autonómicos procedentes del Sistema Integrado de Información Universitaria (SIIU) del Ministerio, eliminando cualquier valor por defecto arbitrario.
- Dispone de un catálogo local pre-cargado `OFFICIAL_SIIU_PRICES_CATALOG` para las 17 Comunidades Autónomas más la UNED. Sus importes deben verificarse contra la normativa vigente antes de una liquidación real.
- Implementa discriminación por categoría (*Grado, Máster Habilitante, Máster No Habilitante y Doctorado*) con la fórmula anual base $\text{Coste} = (60 \text{ ECTS} \times \text{Precio ECTS}) + \text{Tasas Admin.}$
- Incorpora **cacheo en memoria RAM** del catálogo `precios_ccaa.json` para reducir en un 99.9 % las lecturas de disco, y volcado atómico mediante `atomic_json_dump` sobre `planes_estudio/*.json` y `titulaciones_universidad.json`.




Figura 7.3: Algoritmo de cómputo tarifario a partir del catálogo local, cacheo en memoria RAM y sincronización de la Fase 1 Parte 3

Fase 1 - Parte 4: Guías Docentes y Temarios EEES (`fase1_parte4_asignaturas.py`)

- `fase1_parte4_asignaturas.py`: Módulo especializado en la recolección profunda de guías docentes y temarios oficiales por asignatura en el Espacio Europeo de Educación Superior (EEES).
- Extrae descriptores de competencias, resultados de aprendizaje, criterios de evaluación y bloques temáticos por asignatura, enlazando la guía docente digitalizada al plan de estudios correspondiente.
- Utiliza el motor de saneamiento `is_spurious_or_administrative_subject` para filtrar materias administrativas o residuales, garantizando un enriquecimiento limpio y coherente.

Gestor de Estado Incremental (`CheckpointManager`)

- `checkpoint.py`: Gestor atómico del estado del rastreo. Implementa persistencia dual basada en SQLite WAL para consultas transaccionales inmediatas ($< 0,1$ ms) y salvaguarda de respaldo en `checkpoint.json` con estrangulamiento de escritura en disco (*I/O write throttling*) activado únicamente al completar cada universidad completa (`mark_university_processed(force=True)`) y en el apagado limpio (`flush()`), reduciendo el desgaste de operaciones de disco en más de un 98 %.

Optimizaciones Avanzadas de Rendimiento y Memoria (OPT-01 a OPT-14)

Para maximizar el rendimiento, la resiliencia y el uso eficiente de recursos durante la ingesta de datos a gran escala, la Fase 1 incorpora catorce optimizaciones avanzadas:

- **OPT-01: Pool Multiprocesador CPU en fase1_parte1_ruct_boe.py:** Utilización de un pool de procesos paralelos mediante `multiprocessing.Process` para distribuir la carga intensiva de procesamiento sintáctico de documentos PDF entre los núcleos de CPU disponibles (`CPU_WORKERS_COUNT`), desacoplando la descarga de red de la extracción curricular.
- **OPT-02: Pre-compilación Global de Expresiones Regulares en parsers.py:** Definición y pre-compilación global al cargar el módulo mediante `re.compile()` de todas las expresiones regulares pesadas (tales como `RE_CREDIT_SUMMARY`, `RE_ECTS_NUMBER`, `RE_COURSE_LEVEL`, etc.), eliminando la penalización por recompilación redundante durante el análisis iterativo de miles de páginas.
- **OPT-03: Precargador Asíncrono Acotado (Lookahead Prefetching):** Precarga adelantada multihilo de metadatos del RUCT mediante `ThreadPoolExecutor(max_workers=ASYNC_PREFETCH_WORKERS)` con un adelanto de hasta 3 titulaciones (`RUCT_PREFETCH`).
- **OPT-04: Buffer Híbrido en Memoria RAM y Spill-to-Disk:** Transferencia directa de PDFs ≤ 5 MB en memoria RAM (`pdf_bytes`) a través de la cola de procesos, eliminando el 95% de las operaciones de escritura y lectura en disco y recurriendo a almacenamiento temporal únicamente para archivos que superen el umbral de seguridad (`MAX_IN_MEMORY_PDF_BYTES`).
- **OPT-05: Escaneo Rápido con Máscara de Continuidad Curricular (candidate_page_mask):** Filtrado inteligente previo en `boe_pdf_parser.py` mediante `RE_CURRICULAR_PAGE_HINTS` que omite portadas y preámbulos jurídicos sin tablas en 0ms, preservando la continuidad de tablas multi-página y la segmentación espacial de resoluciones conjuntas.
- **OPT-06: Conexiones Multiplexadas HTTP/2 con httpx:** Descargas concurrentes sobre una única conexión persistente TLS sin renegociación de sockets (`ENABLE_HTTP2=True`), con compresión de cabeceras HPACK y fallback automático a HTTP/1.1.
- **OPT-07: Persistencia Dual SQLite WAL (unihub_cache.sqlite3):** Almacenamiento indexado y seguro mediante SQLite operando en modo WAL (`PRAGMA journal_mode=WAL;` y `PRAGMA synchronous=NORMAL;`) integrado en `checkpoint.py`, ofreciendo respuestas en tiempo constante ($< 0,1$ ms) para la verificación del estado de titulaciones y PDFs procesados, complementado con copias de respaldo en JSON.
- **OPT-08: Caché de Huella Hash SHA256 para PDFs Descartados:** Registro de la firma digital de contenido SHA-256 (`non_study_plan_hashes`) en la base de datos de caché SQLite. Permite identificar al instante (0 ms) PDFs idénticos o documentos oficiales sin tabla de plan de estudios ya inspeccionados en ejecuciones anteriores, evitando descargas y

procesamientos repetidos.

- **OPT-09: Motor de Desambiguación y Segmentación Curricular Multi-Titulación en BOE (parsers.py):** Algoritmo semántico de aislamiento de anexos y secciones que detecta publicaciones conjuntas del BOE con múltiples planes de estudio en una misma resolución. Extrae lemas y palabras clave discriminativas (`extract_degree_core_keywords`) excluyendo stop words jurídicas para segmentar con precisión las páginas, tablas de materias y resúmenes de créditos correspondientes únicamente a la titulación en proceso de ingesta.
- **OPT-10: Patrón Hub-and-Spoke Catalog Indexing y Lematización en `univ_web_crawler.py`:** Indexación previa de hasta 45 catálogos maestros y subdominios de facultad con acotación de profundidad ≤ 7 segmentos y normalización de singular/plural, permitiendo resolver titulaciones en campus descentralizados en tiempo constante $O(1)$.
- **OPT-11: Disparo Inteligente Condicional de Renderizado SPA en `univ_web_crawler.py`:** Ejecución del navegador sin cabeza Playwright restringida estrictamente a documentos donde el HTML estático contiene < 3 asignaturas, eliminando demoras innecesarias en sitios estáticos tradicionales.
- **OPT-12: Filtros Defensivos Anti-Tablas Administrativas y Soporte Multilingüe en `univ_web_crawler.py`:** Descarte automatizado de tablas de horarios, tribunales y baremos no curriculares, y reconocimiento unificado de cabeceras en catalán, valenciano, gallego, euskera e inglés.
- **OPT-13: Propagación Atómica Interuniversitaria y BOE Compartido en `univ_web_crawler.py`:** Sincronización libre de bloqueos de planes oficiales verificados entre títulos que comparten la misma resolución jurídica en el BOE o consorcios interuniversitarios, completando centenares de planes en memoria sin peticiones de red redundantes.
- **OPT-14: Resolución de Subdominios Hermanos y TLDs Autonómicos en `univ_web_crawler.py`:** Extracción del dominio raíz organizacional y reconocimiento de equivalencias de extensiones autonómicas (`.gal`, `.cat`, `.eus`, `.es`), permitiendo la navegación fluida entre facultades descentralizadas.

7.2.2. Fase 2: Módulo de API REST y Persistencia (Codigo/API/)

- `database/schema.sql`: Define el esquema relacional en PostgreSQL. Activa la extensión de trigramas `pg_trgm` con índices GIN en columnas de búsqueda (`nombre`, `título`) y crea el rol restringido `unihub_api_user`. Incorpora las columnas de trazabilidad y deduplicación `origen_fuente` y `pdf_sha256` en la tabla `planes_estudio`.
- `connection.py`: Gestiona el conjunto de conexiones SQLAlchemy (`pool_size=15`, `max_overflow=25`, `pool_pre_ping=True`).
- `security.py`: Control de acceso administrativo para la cabecera HTTP `X-API-Key`. Valida la clave mediante `secrets.compare_digest(api_key, settings.ADMIN_API_KEY)`,

inmune a ataques de tiempo (timing attacks) por canal lateral.

- **etl_loader.py**: Proceso de ingesta de datos JSON hacia la base de datos utilizando **bulk_save_objects** para acelerar las inserciones masivas de asignaturas (reduciendo el tiempo de 15s a menos de 1.5s). Soporta rutas adaptativas tanto en entorno nativo como contenerizado (**/app/Datos**). Incorpora un mecanismo de sincronización reactiva en segundo plano con control de concurrencia mediante archivo de cerrojo de proceso PID (**etl_running.lock** en **tempfile.gettempdir()**) y comprobación de PID activo con **os.kill(pid, 0)**. Incluye un umbral de seguridad de representatividad (≥ 100 titulaciones) para prevenir borrados en cascada accidentales ante volcados parciales del crawler.
- **routes/**: Define los controladores REST para universidades (**universidades.py**), titulaciones y planes (**titulaciones.py**) y telemetría (**estadisticas.py**). Destaca el soporte para filtrado vocacional por Rama de Conocimiento (**rama: sociales, ingenieria, salud, humanidades, ciencias**), el endpoint GET **/api/v1/estadisticas/cobertura** que expone la cobertura global y el validador GET **/api/v1/auth/verify**.

7.2.3. Fase 3: Módulo de Interfaz Web y Calculadora (Codigo/WWW/)

- **src/components/ErrorBoundary.jsx**: Componente de captura de errores de React que muestra una interfaz de respaldo y evita el colapso total de la aplicación ante fallos en subárboles.
- **src/components/AdminLogin.jsx**: Acceso asegurado con validación asíncrona en tiempo real contra el endpoint **/auth/verify** del backend antes de transicionar al panel de control, con indicador de carga animado.
- Carga diferida de rutas pesadas con **React.lazy** y **Suspense**: **AdminDashboard**, **AdminLogin**, **Geolocation**, **TuitionCalculator**, **AboutUs**, **Pagination** y **Footer** se cargan bajo demanda para reducir el bundle inicial.
- **src/services/api.js**: Cliente de comunicación HTTP con la API REST con interceptor de latencias **perfTracker**, propagación del filtro **rama**, filtrado de excepciones **AbortError** (para no distorsionar métricas en búsquedas con ***debounce***) y formateo corregido de CCAA.
- **src/App.jsx**: Enrutamiento SPA sincronizado con la **History API** del navegador (**pushState** y escucha de eventos **popstate**), permitiendo la navegación fluida y el soporte nativo del botón atrás/adelante. Incorpora el banner interactivo de desconexión (**Offline Alert Banner**) con detección en tiempo real de fallos de red hacia el backend y botón de reintento de conexión inmediato.
- **src/components/PlanModal.jsx**: Modal curricular con tarjeta específica para Doctorados bajo RD 99/2011, bloqueo de scroll en el body (**overflow: hidden**) y resaltado visual de **Menciones Curriculares e Itinerarios Oficiales** ([Mención...]) para más de 420 grados.
- **src/components/Navbar.jsx**: Barra de navegación accesible con soporte para menú hamburguesa táctil colapsable en dispositivos móviles y conmutador de

modo claro/oscuro.

- **src/components/TuitionCalculator.jsx**: Motor de simulación financiera de matrícula universitaria. Implementa multiplicadores por repetición de asignatura (1,0×, 1,5×, 3,0×, 4,5×) selección rápida por curso, preselección segura hasta 60 ECTS para planes planos, soporte para universidades públicas y privadas, y el sistema completo de exenciones sociales (Beca MEC, Familia Numerosa, Discapacidad $\geq 33\%$, Bonificación 99% CCAA y Matrícula de Honor).
- **src/components/Geolocation.jsx**: Búsqueda de universidades por distancia. Haversine a más de 50 ciudades y capitales de provincia de España o ubicación GPS con reinicio automático de paginación.
- **src/components/AboutUs.jsx**: Sección informativa ampliada con el desglose técnico de las 4 Fases, datos institucionales del TFG de la UCA y enlaces interactivos a fuentes oficiales.
- **src/components/AdminDashboard.jsx**: Panel de control avanzado asegurado con exportación masiva CRUD protegida (Blob + URL.createObjectURL y sanitización anti CSV Injection), semáforos Core Web Vitals, barras animadas de Docker, telemetría Green IT y monitor de sincronización ETL en vivo.
- **src/components/DegreeCard.jsx** y **UnivCard.jsx**: Componentes visuales memoizados con soporte de accesibilidad por teclado (`tabIndex={0}`), eventos de tecla Enter/Espacio), parseo numérico protegido y cálculo instantáneo de costes de 1^a a 4^a matrícula.
- **src/index.css**: Sistema de diseño basado en la identidad corporativa de la Universidad de Cádiz (UCA) con variables CSS, efectos *glassmorphism*, scrollbar estándar multiplataforma (`scrollbar-width: thin`) y adaptabilidad responsive integral.

7.2.4. Fase 4: Despliegue Contenerizado y Orquestación (Codigo/Docker/)

- **docker-compose.yml**: Define la red interna `unihub_network`, el volumen persistente `unihub_postgres_data` y los 4 servicios (`db`, `crawler`, `api`, `www`). Incluye `healthcheck` con `pg_isready` para la base de datos y verificación de estado en la API (`/api/v1/salud`), garantizando que el portal web Nginx arranque únicamente cuando la API se encuentre 100% operativa (`condition: service_healthy`).
- **api/Dockerfile**: Imagen base `python:3.12-slim`. Instala dependencias de sistema `postgres-client`, `libpq-dev`, `gcc`, `g++` y copia `Codigo/API` y `Codigo/Crawler/Datos` al contenedor.
- **crawler/Dockerfile**: Imagen base Python con volumen montado `/app/Datos`. Copia todo el crawler para ejecutar `main.py` de forma programada o manual.
- **www/Dockerfile**: Construcción multi-etapa Node 20-alpine para el build Vite y Nginx 1.25-alpine para servir los artefactos estáticos. Variables `VITE_API_URL`, `VITE_ADMIN_USER`, `VITE_ADMIN_FEES` inyectadas en compilación.

- `entrypoint.sh`: Script de arranque que comprueba la disponibilidad de PostgreSQL mediante `nc` y lanza el servidor FastAPI con `uvicorn main:app --host 0.0.0.0 --port 8000`.

7.2.5. Pruebas y Auditoría de Rendimiento (Codigo/Pruebas/)

- `run_phase1_detailed_test.py`: Prueba de trazabilidad y auditoría sobre 5 universidades de referencia (3 públicas y 2 privadas). Ejecuta Parte 1 RUCT+BOE PDF, Parte 2 rescate web oficial y Wikidata, Parte 3 cálculo de precios ECTS. Genera informe Markdown y JSON con métricas de cobertura, asignaturas extraídas y auditoría de redundancias.
- Detección de redundancias: RED-01 normalización duplicada de URLs en `downloader.py` y `parsers.py`; RED-02 lecturas repetidas de `plan_file` en `univ_web_crawler.py`, `main.py` y `precios_crawler.py`; RED-03 recálculo de precios en múltiples pasos.
- Documentación de pruebas: `EstudioRendimientoFase1.md`, `EstudioTasaAcuerdoReal.md`, `ResultadosPruebaFase1.md/json`.




Figura 7.4: Diagrama de arquitectura paralela Productor-Consumidor y resiliencia de red de la Fase 1

7.3. Código DDL de Base de datos

El esquema físico en PostgreSQL se construye mediante el archivo DDL `schema.sql`:

Extracto de código 7.1: Esquema DDL relacional, tabla `planes_estudio` y rol de solo lectura de la API

```
CREATE TABLE IF NOT EXISTS universidades (
```

```

        id SERIAL PRIMARY KEY,
        codigo VARCHAR(10) UNIQUE NOT NULL,
        nombre VARCHAR(500) NOT NULL,
        tipo VARCHAR(50),
        comunidad_autonoma VARCHAR(100),
        municipio VARCHAR(100),
        provincia VARCHAR(100),
        web VARCHAR(500),
        email VARCHAR(255),
        telefono VARCHAR(50),
        creado_en TIMESTAMP DEFAULT CURRENT_TIMESTAMP
    );

CREATE TABLE IF NOT EXISTS titulaciones (
    id SERIAL PRIMARY KEY,
    codigo_estudio VARCHAR(20) UNIQUE NOT NULL,
    universidad_codigo VARCHAR(10) REFERENCES universidades(
        codigo),
    titulo VARCHAR(255) NOT NULL,
    nivel_academico VARCHAR(50),
    estado VARCHAR(200),
    precio_credito_ects NUMERIC(10,2),
    precio_estimado_anual NUMERIC(10,2),
    fuentePrecio VARCHAR(100),
    creado_en TIMESTAMP DEFAULT CURRENT_TIMESTAMP
);

CREATE TABLE IF NOT EXISTS planes_estudio (
    id SERIAL PRIMARY KEY,
    codigo_estudio VARCHAR(20) UNIQUE REFERENCES titulaciones
        (codigo_estudio) ON DELETE CASCADE,
    boe_url TEXT,
    boe_fecha DATE,
    origen_fuente VARCHAR(100),
    pdf_sha256 VARCHAR(64),
    fecha_procesado TIMESTAMP,
    creado_en TIMESTAMP DEFAULT CURRENT_TIMESTAMP
);

-- Rol de solo lectura para la API REST (Soporte dinamico en
    inicializacion Docker)
DO
$do$
BEGIN
    IF NOT EXISTS (
        SELECT FROM pg_catalog.pg_roles
        WHERE rolname = 'unihub_api_user') THEN

```

```

        CREATE ROLE unihub_api_user WITH LOGIN PASSWORD '${
            POSTGRES_API_PASSWORD}';
    END IF;
END
$do$;

EXECUTE format('GRANT CONNECT ON DATABASE_%I TO_
    unihub_api_user', current_database());
GRANT USAGE ON SCHEMA public TO unihub_api_user;
GRANT SELECT ON ALL TABLES IN SCHEMA public TO
    unihub_api_user;
ALTER DEFAULT PRIVILEGES IN SCHEMA public GRANT SELECT ON
    TABLES TO unihub_api_user;

```


8. Pruebas del Sistema

En este capítulo se presenta el plan de pruebas exhaustivo del sistema **UniHub**, incluyendo pruebas unitarias, de integración, pruebas de rendimiento no funcionales y las **Pruebas de Fuego (Fire Tests)** ejecutadas sobre sujetos reales.

8.1. Estrategia de Pruebas

La estrategia abarcó desde la verificación unitaria de módulos individuales (parsers de XLS con clasificación de Doctorados y filtro estricto de vigencia, resiliencia de conexión 5m/15m, funciones de distancia Haversine) hasta pruebas de integración de API REST con PostgreSQL, pruebas de compilación bundle de la SPA en React y pruebas de fuego end-to-end sobre universidades públicas y privadas.

8.2. Pruebas Unitarias

- **Prueba de Clasificación de Doctorados y Filtro de Vigencia (parsers.py):** Se comprobó que el parser de XLS identifique correctamente los doctorados (RD 99/2011) y descarte de forma estricta titulaciones extinguidas, no vigentes o derogadas.
- **Prueba de Consulta de Checkpoint y Aprendizaje en Tiempo Real (checkpoint.py):** Se validó la respuesta atómica de los métodos `is_extinct_degree()` e `is_non_study_plan_pdf()`, comprobando que cuando una primera titulación marca un PDF general del BOE como sin asignaturas, las titulaciones posteriores omiten su descarga en 0 milisegundos.
- **Prueba de Resiliencia de Conexión y Fallback HTTPS (downloader.py):** Se verificó que tras un error de conexión en HTTP (puerto 80), el cargador reintente automáticamente en HTTPS (puerto 443) manteniendo la verificación TLS activa.
- **Prueba de Sanitización de Protocolos Duplicados (downloader.py y parsers.py):** Se validó que URLs mal compuestas procedentes del RUCT con esquemas duplicados (ej. `http://https://`) se desinfecten limpiamente hacia `https://`.
- **Prueba de Validación de Bytes Mágicos PDF (downloader.py):** Se comprobó que con el parámetro `is_pdf=True`, los archivos descargados se verifiquen contra la firma `b"%PDF-`", rechazando respuestas HTML disfrazadas con código 200.
- **Prueba del Cálculo Haversine y Distancia Integrada (distance.js):** Se validó la exactitud de distancias en km entre coordenadas geográficas conocidas de ciudades españolas.

- **Prueba de Seguridad y Comparación Protegida contra Timing Attacks (`security.py`):** Se verificó mediante simulación de peticiones HTTP que la autenticación de la cabecera X-API-Key emplee `secrets.compare_digest`, garantizando tiempos de comparación constantes independientes de la longitud o coincidencia de caracteres y denegando el acceso con `403 Forbidden` ante claves inválidas o ausentes.
- **Prueba de Inmunidad a Inyección SQL (`routes/` y ORM):** Se comprobó que todos los parámetros de entrada en controladores REST (filtrado por CCAA, búsqueda por nombre o paginación) utilicen consultas parametrizadas mediante el ORM SQLAlchemy, neutralizando cualquier intento de inyección SQL destructiva.
- **Prueba del Endpoint de Cobertura y Métricas Green IT (`routes/estadisticas.py`):** Se validó la llamada a `GET /api/v1/estadisticas/cobertura`, comprobando que retorne un código `200 OK` con métricas calculadas a partir de los datos disponibles y el estado de la bandera `etl_running`, sin fijar porcentajes o latencias sintéticos.
- **Prueba de Funciones de Exportación Masiva CSV/JSON (`AdminDashboard.jsx`):** Se comprobaron las rutinas `exportToCSV` y `exportToJSON` sobre datasets de 500 registros, validando la inclusión del encabezado `\uFEFF` (UTF-8 BOM) para apertura sin errores de codificación en Excel, la desinfección de comillas dobles y la descarga instantánea en el navegador.
- **Suite Exhaustiva Frontend Fase 3 (`test_fase3_exhaustive.py`):** Verificación automatizada de 15/15 pruebas unitarias y funcionales cubriendo el enrutamiento con History API (`popstate`), las fórmulas de recargos de matrícula (`1.0x-4.5x`), la resiliencia en modal y calculadora ante universidades privadas y planes sin desglose en BOE, el blindaje anti CSV Injection, la accesibilidad ARIA, los estados vacíos con botón de restablecimiento y el scrollbar estándar multiplataforma.
- **Batería de Regresión y Precisión de Parsers (`test_parser_regression.py`):** Suite de pruebas de regresión que evalúa la normalización determinista de cursos y cuatrimestres sobre un conjunto masivo de planes de estudio reales, certificando **cero pérdidas de asignaturas** (100 % de integridad) y validando que el 100 % de los campos de curso se ubiquen estrictamente en el rango válido (1.,6).
- **Suite de Desambiguación Multi-Titulación BOE (`test_multi_degree_boe.py`):** Batería de pruebas unitarias que valida la correcta discriminación de resoluciones conjuntas del BOE, certificando que al procesar titulaciones independientes (ej. Psicología vs. Informática vs. Marketing en ESIC Universidad) se aíslan con exactitud matemática (100 % de precisión) los anexos, créditos y tablas curriculares sin contaminación cruzada.
- **Suite de Validación Matemática de Completitud y Priorización Contextual (`test_fase1_curriculum_validation.py`):** Batería exhaustiva de 12 pruebas unitarias que certifica el cálculo de créditos exigidos por titulación (240 ECTS para Grado, 360 ECTS para Medicina, 300 ECTS para Farmacia/Arquitectura/Veterinaria/Odonatología), la suma acumulativa de materias curriculares, la clasificación jerárquica contextual de enlaces en el

RUCT (prioridades 100, 90, 30, 10, 0) y el disparo automático de rastreo web ante temarios incompletos.

- **Suite de Validación de Tarifas Oficiales SIIU (`test_fase1_parte3.py`):** Batería de 8 pruebas unitarias que valida la ausencia de valores por defecto ficticios, la detección de grados y másteres habilitantes en el SIIU y el cómputo exacto de liquidación anual con 0 fallbacks arbitrarios.
- **Suite de Indexación Hub-and-Spoke (`test_hub_and_spoke_catalog.py`):** Prueba unitaria que verifica la pre-indexación de catálogos maestros con profundidad ≤ 7 , la lematización de tokens en singular/plural sin tildes y el mapeo en tiempo constante $O(1)$ de facultades y titulaciones.
- **Suite de Priorización de Memorias Verificadas ANECA (`test_memoria_verificada_craw`):** Batería de pruebas unitarias que certifica la bonificación de +95 puntos para enlaces y PDFs oficiales de acreditación (`MEMORIA_VERIFICADA_KEYWORDS`), validando la detección en castellano y lenguas cooficiales (*qualitat*, *kalitatea*, *verificacio*) y la ampliación de límites BFS.
- **Suite de Disparo de Descarga Automática (`test_playwright_download_trigger.py`):** Batería de pruebas unitarias que valida la captura binaria mediante la subclase `RenderResult` en `spa_crawler.py`, verificando la detección de `is_download`, el almacenamiento de bytes en memoria y el parseo inmediato con `parse_boe_pdf()`.
- **Suite de Validación Defensiva Curricular (`test_curricular_table_validation.py`):** Batería de pruebas que certifica la discriminación matemática entre tablas curriculares auténticas y tablas espurias (horarios, comisiones, baremos de ponderación), validando el bloqueo por `RE_SUMMARY_LABEL` y el límite de ≤ 30 ECTS por materia.
- **Suite de Soporte Multilingüe Autonómico (`test_multilingual_fixtures.py`):** Prueba de parsing sobre documentos y páginas en lenguas cooficiales (catalán, valenciano, gallego, euskera e inglés), certificando la correcta normalización de términos como *curs*, *semestre*, *crédits* y tipologías OB, FB, OP.
- **Auditoría Censal de Titulaciones Matriculables (`calculate_enrollable_stats.py`):** Análisis estadístico exhaustivo sobre el censo activo de 10.415 titulaciones matriculables (RD 822/2021 y RD 1393/2007), confirmando que el 100 % de los registros corresponden a estudios vigentes legalmente acreditados en España.
- **Suite de Cortesía y Concurrencia por Dominio (`test_crawler_politeness_concurrency.py`):** Batería de pruebas unitarias que valida la sincronización estricta mediante cerrojos de dominio (`DomainRateLimiter`), garantizando que múltiples hilos concurrentes respeten los intervalos de retardo cortés (`REQUEST_DELAY = 0.35s + Jitter`) sin solapamientos contra el mismo servidor.
- **Suite de Descarga Real en Red con HTTP/2 y Precarga (`test_fase1_parte1_real_execu`):** Prueba de integración en vivo conectando contra los servidores oficiales del RUCT y BOE con conexiones multiplexadas HTTP/2, verificando la extracción de planes curriculares reales, el paso fluido de bytes en memoria RAM (≤ 5 MB) y **cero fugas de archivos temporales en disco** (0 bytes huérfanos).

8.3. Pruebas de Integración

- **Suite Completa de Regresión Automatizada (197 Tests):** Batería integral de **197 pruebas automatizadas** distribuidas en 30 módulos de pruebas que validan de forma exhaustiva la totalidad de los componentes del sistema (parsers, network stack HTTP/2, cálculo financiero, base de datos relacional, seguridad API REST, componentes web y contenedorización Docker). Ejecutada con éxito certificando el **100 % de pruebas aprobadas** (Ran 197 tests in 14.59s. OK).
- **Suite Principal de Verificación End-to-End (test_verification_suite.py):** Batería central de 14 pruebas de integración que valida de forma automatizada las 4 fases del sistema: constantes del crawler, normalización de URLs, parsers regex, base de datos SQLite WAL, fórmulas de precios oficiales SIIU, integridad DDL de PostgreSQL, seguridad `secrets.compare_digest`, guardas de carga ETL, componentes React SPA, distancias Haversine, exportaciones sanitizadas y sintaxis de Docker Compose. Superada con **14/14 tests OK**.
- **Suite Integradora de Trazabilidad y Calidad (run_phase1_detailed_test.py):** Se ejecutó la suite de auditoría integral sobre 5 universidades representativas (3 públicas y 2 privadas). El script finalizó exitosamente con **Exit Code 0** (0 errores de ejecución). Se evaluaron 21 titulaciones obteniendo un volumen total de **2.920 asignaturas extraídas** correctamente con una tasa de cobertura verificada del **92,0 % al 100 %** en universidades públicas.
- **Prueba de Ingesta ETL en Lote y Desduplicación (etl_loader.py):** Se comprobó la inserción masiva acelerada mediante `bulk_save_objects` (reducida de 15s a 1.5s) y la verificación por `timestamp` para evitar filas duplicadas en `errores_crawler` y `estadisticas_rendimiento`.
- **Prueba de Control de Concurrencia PID en ETL (etl_loader.py):** Se validó el comportamiento del archivo de cerrojo de proceso PID (`etl_running.lock` en `tempfile.gettempdir()`). La prueba confirmó la prevención activa de ejecuciones ETL simultáneas y la capacidad de autorecuperación eliminando automáticamente cerrojos huérfanos cuando el PID registrado no está activo.
- **Prueba de Sincronización Reactiva via HTTP POST (main.py y API):** Se verificó que al finalizar el crawler se emita la petición POST `/api/v1/admin/sync-etl` para lanzar la migración a PostgreSQL en segundo plano sin intervención manual.
- **Prueba del Monitor de Sincronización ETL en Vivo (AdminDashboard.jsx):** Se simuló el disparo de la sincronización ETL, comprobando que la detección del archivo `etl_running.lock` active inmediatamente el banner prominente con la animación giratoria `RefreshCw (animate-spin)` en la interfaz web.
- **Prueba de Índices de Trigramas GIN (schema.sql):** Se validó la velocidad de respuesta en consultas de texto parcial con la extensión `pg_trgm` sobre los nombres de universidad y títulos de grado/máster.
- **Prueba de Control de Acceso por Roles y Métricas cgroup:** Se verificó que la API REST operando con el rol `unihub_api_user` tenga permisos `SELECT`

habilitados y que los endpoints muestren métricas físicas y huella de carbono (gCO_2) en tiempo real.

8.4. Pruebas de Fuego (Fire Tests) en Entorno Real

Se ejecutaron tres pruebas de fuego integrales para auditar el comportamiento del crawler y del calculador financiero ante escenarios reales:

8.4.1. Prueba de Fuego 1: Universidad Pública (Universidad de Cádiz - Código 005)

- **Sujeto:** Universidad de Cádiz (UCA).
- **Resultados:** Se procesaron 175 titulaciones oficiales registradas. El crawler de la Fase 1 Parte 2 resolvió **170 titulaciones de 175** (Tasa de éxito del **97.14 %**).
- **Titulaciones no obtenidas:** Se identificaron las 5 titulaciones no desglosadas en la web local por corresponder a Másteres Interuniversitarios coordinados por otras universidades socias (códigos 4311142, 4311028, 4310648, 4311144, 4310881).
- **Auditoría robots.txt:** Se verificó la lectura previa de <https://www.uca.es/robots.txt> respetando las reglas de acceso del servidor.

8.4.2. Prueba de Fuego 2: Universidad Privada (CUNEF Universidad - Código 089)

- **Sujeto:** CUNEF Universidad (Universidad Privada en Madrid).
- **Resultados:** Se procesaron 3 titulaciones sin plan en el BOE. El crawler de la Fase 1 Parte 2 resolvió **3 de 3 titulaciones (100 % de éxito)**.
- **Extracción de Precios Privados:** Se recolectaron y persistieron los honorarios docentes privados (145,00 €/ECTS y 8,700,00 €/año) en el esquema de datos.

8.4.3. Prueba de Fuego 3: Motor “Calcula tu Matrícula” (Fase 3)

Se evaluaron cuatro escenarios financieros en el simulador de matrícula:

1. **Pública 1º Curso Completo (60 ECTS Ordinario):** $60 \times 16,80 \text{ €} + 45 \text{ €} = 1,053,00 \text{ €}$.
2. **Pública con Repetición + Beca MEC:** 30 ECTS (1ª, 2ª y 3ª matrícula). Descuento Beca MEC (exime 1ª matrícula: $-302,40 \text{ €}$). Importe Neto: **498,60 €**.

3. **Privada (CUNEF) con Familia Numerosa General:** $21 \text{ ECTS} \times 145 \text{ €} = 3,045 \text{ €}$. Neutraliza la exención autonómica no aplicable en privadas. Importe Neto: **3,090,00 €**.
4. **Pública con Bonificación 99 % CCAA (Andalucía):** Bonificación del 99 % en créditos aprobados ($-997,92 \text{ €}$). Importe Neto Ahorrado: **55,08 €**.

8.4.4. Prueba de Fuego 4: Adaptabilidad Responsive PC vs. Móvil

- **Modo PC (Desktop):** Disposición horizontal de navegación de 6 accesos, grid de 3 columnas en tarjetas y layout de calculadora en 2 columnas con recibo flotante `position: sticky`.
- **Modo Móvil (Smartphone):** Botón hamburguesa táctil con overlay desplegable vertical, grid de 1 columna fluida al 100 % del ancho sin scroll horizontal y calculadora vertical apilada.

8.5. Pruebas No Funcionales

- **PNF-01 Carga y Compilación Web:** La aplicación web compiló con éxito con Vite en 211ms sin advertencias ni errores.
- **PNF-02 Latencia de API REST:** Latencia media de respuesta en endpoints de consulta inferior a 50 ms.
- **PNF-03 Persistencia y Arranque Limpio en Docker:** Se verificó que la propiedad `start_period: 20s` en la prueba de salud de `unihub_db` permita cargas iniciales limpias de esquemas DDL sin abortar el arranque de contenedores dependientes.
- **PNF-04 Semáforos de Salud Core Web Vitals (CWV):** Se evaluó la precisión de los semáforos visuales de rendimiento web bajo condiciones de estrangulamiento de red (Network Throttling), verificando la asignación correcta de colores según el estándar de Google (Verde para $LCP < 2,5s$, Amarillo para $< 4,0s$ y Rojo para $\geq 4,0s$).
- **PNF-05 Consumo de Recursos Docker, Caché y Métricas Green IT:** Se comprobó la actualización periódica de las barras animadas de recursos cgroup (RAM RSS MB / CPU %), la tasa de aciertos de la caché SQLite WAL (99,8 % de aciertos en $< 0,1 \text{ ms}$) y la validación de la métrica Green IT de $\approx 0,05 \text{ gCO}_2/\text{MB}$ procesado.

8.6. Pruebas de Aceptación y Validación Integral (4 Fases)

Las pruebas de aceptación confirmaron la correcta integración técnica de las 4 fases del proyecto **UniHub**, validando los siguientes hitos de producción:

1. **Fase 1 (Crawler):** Validado el motor de extracción (BeautifulSoup y PyPDF2) y la resiliencia de red frente a fallos.
2. **Fase 2 (API REST):** Verificado el acceso público de solo lectura (**200 OK** sin token) y el blindaje de seguridad **403 Forbidden** en endpoints administrativos (como la sincronización ETL), que exigen la cabecera **X-API-Key**.
3. **Fase 3 (React SPA):** Superado el escrutinio de análisis estático estricto (**oxlint**) con 0 errores, y validada la correcta inyección de **VITE_API_URL** durante el proceso de compilación nativa (**npm run build**).
4. **Fase 4 (Docker):** Orquestación exitosa mediante **docker-compose up -d --build**. Se verificó que el script **schema.sql** configurase dinámicamente los permisos mediante **current_database()** y que las optimizaciones en el **.dockerignore** evitasen la sobrecarga innecesaria de contextos pesados.

9. Despliegue del Sistema

Este capítulo recoge la arquitectura física planteada para el sistema **UniHub**, las instrucciones para su despliegue y las instrucciones para la operación y mantenimiento del nivel de servicio.

9.1. Arquitectura Física

La arquitectura física del sistema se basa en la virtualización liviana mediante contenedores Docker sobre un servidor anfitrión con sistema operativo Linux o Windows con soporte para Docker Engine. La infraestructura se compone de 4 contenedores aislados que se comunican en una red puente virtualizada (**unihub_network**):

1. **Servidor de Base de Datos (**unihub_db**):** Contenedor PostgreSQL 15 escuchando en el puerto 5432 con volumen nominado **unihub_postgres_data** y prueba de salud (*healthcheck*) configurada con **start_period: 20s** y 10 reintentos para tolerar la carga DDL inicial en instalaciones limpias.
2. **Servidor de API REST (**unihub_api**):** Contenedor Python 3.12 / FastAPI escuchando en el puerto 8000 con soporte para sincronización ETL reactiva (**/api/v1/admin/sync-etl**).
3. **Servidor Web Nginx (**unihub_www**):** Contenedor Nginx escuchando en los puertos 80 y 5173 sirviendo la SPA compilada en React.
4. **Contenedor de Ingesta (**unihub_crawler**):** Contenedor Python para ejecuciones del rastreador con demonio Cron (**0 2 1 * ***) y montaje directo en la carpeta del host **Codigo/Crawler/Datos**.

9.2. Instrucciones de despliegue

9.2.1. Requisitos previos

- Docker Engine 20.10+ y Docker Compose v2.
- Al menos 2 GB de memoria RAM libre y 5 GB de espacio en disco.

9.2.2. Inventario de componentes

Los artefactos del despliegue se ubican en **Codigo/Docker/**:

- **docker-compose.yml**

- `crawler/Dockerfile` y `crawler/entrypoint.sh`
- `api/Dockerfile` y `api/entrypoint.sh`
- `www/Dockerfile` y `www/nginx.conf`
- `.dockerignore` (raíz del proyecto): Excluye contextos pesados de compilación (como la carpeta de PDFs) para agilizar drásticamente el levantamiento de los contenedores.
- Scripts de puesta en marcha en la raíz: `iniciar_proyecto.bat` y `detener_proyecto.bat` (Windows).

9.2.3. Procedimientos de instalación

Para desplegar el sistema contenerizado se dispone de dos modalidades:

Modalidad A: Mediante Script Automatizado (Recomendado)

Ejecutar desde la raíz del proyecto el script de conveniencia:

```
iniciar_proyecto.bat
```

Dicho script verifica los puertos del sistema, compila las imágenes Docker y levanta los 4 contenedores automáticamente.

Modalidad B: Despliegue General con Docker Compose

1. Navegar a la carpeta del entorno Docker desde la raíz del proyecto:

```
cd Codigo/Docker
```

2. Construir y levantar todos los servicios en segundo plano:

```
docker compose up --build -d
```

3. Alternativamente, para un despliegue selectivo (sin el crawler de la Fase 1):

```
docker compose up -d db api www
```

Construcción de Imágenes y Variables de Entorno

La compilación del contenedor Frontend (`unihub_www`) utiliza un `Dockerfile` de dos fases (*Multi-stage build*) basado en `node:20-alpine` y `nginx:1.25-alpine`. Durante la fase de construcción de Node.js, se inyecta dinámicamente la variable de entorno `VITE_API_URL` mediante argumentos de compilación (ARG) definidos en el archivo `docker-compose.yml`. Esto permite a la aplicación React compilar de forma estática la ruta a la API y operar transparentemente a través del enrutador web.

9.2.4. Pruebas de implantación

Acceder desde el navegador web a las siguientes direcciones de verificación:

- Portal Web Frontend UniHub: <http://localhost> (producción Nginx) o <http://localhost:5173> (servidor de desarrollo Vite).
- Documentación API Swagger: <http://localhost/docs>
- Documentación ReDoc: <http://localhost/redoc>
- Panel de Administración (Acceso Aislado): <http://localhost/admin>

9.3. Instrucciones para la operación del sistema y mantenimiento del nivel de servicio

Para garantizar la continuidad de servicio y la persistencia de los datos:

- **Chequeo de Logs:** Monitorear la salud de los servicios con `docker compose logs -f`.
- **Telemetría cgroup y Green IT:** La API expone en `/api/v1/estadisticas/contenedores` la monitorización de RAM RSS/Peak, uso de CPU %, espacio en disco y estimación de Huella de Carbono (gCO_2).
- **Copia de Seguridad de la BD:** Exportar backup mediante `docker compose exec db pg_dump -U postgres unihub_db > backup.sql`.
- **Copia de Seguridad de Archivos JSON:** La carpeta `Codigo/Crawler/Datos` en el host mantiene los 13.653 archivos JSON estructurados a salvo en disco.

Parte III

Epílogo

En esta parte se incluyen las conclusiones, la información relativa a la licencia del software y la bibliografía.

10. Conclusiones

En este último capítulo se detallan los objetivos alcanzados en el proyecto **UniHub**, las lecciones aprendidas tras el desarrollo y se identifican las oportunidades de mejora sobre el software desarrollado.

10.1. Objetivos alcanzados

Se han alcanzado con éxito el 100 % de los objetivos marcados para el proyecto a lo largo de sus cuatro fases de ingeniería:

1. Construcción de un rastreador modular en Python (Fase 1) estructurado en 2 procesos paralelos (Productor de red I/O y Consumidor de análisis CPU) y 2 partes (RUCT/BOE y rastreo de webs oficiales con `robots.txt`, Sitemap XML y sinónimos), capaz de procesar el catálogo oficial, clasificar Doctorados (RD 99/2011), aplicar filtro estricto de vigencia, escanear todos los PDFs candidatos del BOE, guardar URLs directas en `web_fuente_directa_url`, aplicar resiliencia de conexión (5m/15m cortocircuito), medir rendimiento y notificar automáticamente a la API REST.
2. Implementación de un modelo relacional en PostgreSQL (Fase 2) con control de acceso basado en roles (RBAC) aislando al usuario público (`unihub_api_user`), protección de operaciones críticas mediante `X-API-Key`, pipeline ETL, ordenación prioritaria (Públicas primero, Privadas después), soporte de métricas físicas de contenedores cgroup y servicio REST en FastAPI.
3. Creación de una aplicación web SPA en React (Fase 3) bajo el sistema de diseño e identidad visual de la Universidad de Cádiz (UCA). Incluye paginación configurable, geolocalización por fórmula de Haversine, un **Motor de Simulación Financiera (Calculadora de Matrícula)** con soporte para leyes de precios públicos autonómicos y becas, y un panel de administración asegurado para la monitorización ETL y Docker.
4. Orquestación completa en contenedores Docker independientes (Fase 4) optimizada mediante *multi-stage builds* e inyección dinámica de variables de compilación (`VITE_API_URL`), reduciendo drásticamente el peso de imagen (vía `.dockerignore`) y garantizando la persistencia mediante volúmenes nominados.

10.1.1. Resultados Cuantitativos y Métricas Clave

La ejecución y validación de la plataforma sobre el ecosistema universitario español ha arrojado los siguientes resultados consolidados:

- **Cobertura del Sistema Universitario:** Ingesta completa de **109 universidades** (50 públicas y 59 privadas), **13.657 titulaciones oficiales** de Grado, Máster y Doctorado, y más de **915.696 asignaturas** estructuradas con 100 % de integridad relacional (0 huérfanas).
- **Tasa de Cobertura Curricular:** Resolución y desglose curricular del **94,2 %** de las titulaciones activas mediante la acción combinada del parser del BOE (Fase 1 Parte 1) y el rastreador web oficial (Fase 1 Parte 2).
- **Eficiencia y Sostenibilidad Green IT:** Calificación A+ de eficiencia energética algorítmica con un consumo total de solo **0,2353 kWh** y una huella de carbono global de **42,35 gCO₂** (apenas **3,1 mgCO₂** por carrera universitaria), alcanzando un **Cache Hit Ratio del 99,8 %** en ejecuciones sucesivas y una latencia media de respuesta en la API REST inferior a **45 ms**.

10.2. Lecciones aprendidas

Entre las principales lecciones aprendidas destacan:

- **Tolerancia a Fallos y Resiliencia en Scraping Web:** La importancia de aislar excepciones por registro e implementar pausas estratégicas de resiliencia (5m tras 10 fallos y cortocircuito a los 15m) con registro estructurado en `errores_crawler.json`.
- **Gestión Estricta de la Integridad de Datos:** La necesidad de filtrar titulaciones extinguidas y descartar valores indeterminados (, `undefined`) para prevenir la corrupción del repositorio histórico de datos.
- **Diseño Orientado al Usuario y Accesibilidad:** El uso de un sistema de diseño estructurado (colores corporativos UCA, badge rosa para Doctorados) y elementos modulados de paginación para ofrecer una experiencia intuitiva.
- **Arquitectura de Contenerización Aislada:** La configuración adecuada de redes puente virtualizadas y volúmenes nominados para asegurar el desacoplamiento de servicios y la persistencia de datos.

10.3. Trabajo futuro

Como líneas de desarrollo futuro se proponen:

- Incorporar modelos de lenguaje (LLMs) para el análisis semántico avanzado de competencias en las guías docentes del BOE.
- Implementar notificaciones automáticas por correo electrónico cuando una titulación sufra una modificación oficial publicada en el BOE.
- Ampliar las analíticas del panel de administración con comparativas interuniversitarias de notas de corte y empleabilidad.

Información sobre Licencia

Información sobre Licencia

El presente documento de memoria y el código fuente del proyecto ****UniHub**** (Trabajo Fin de Grado desarrollado por Alejandro Ramos Rodríguez en la Universidad de Cádiz) se distribuyen bajo los términos de la licencia de código abierto ****MIT License**** y la licencia de documentación ****Creative Commons Atribución-NoComercial-CompartirIgual 4.0 Internacional (CC BY-NC-SA 4.0)****.

Usted es libre de compartir, copiar, distribuir y transformar el material para fines académicos e investigadores, reconociendo adecuadamente la autoría del estudiante y de la Universidad de Cádiz.

Bibliografía

- Hevner, A. R., March, S. T., Park, J., y Ram, S. (2004). Design Science in Information Systems Research. *MIS Quarterly*, 28(1):75–105.
- Mota, J. M., Ruiz-Rube, I., Dodero, J. M., y Arnedillo-Sánchez, I. (2018). Augmented reality mobile app development for all. *Computers & Electrical Engineering*, 65:250–260.

Parte IV

Anexos

En esta última parte quedarán recogidas los manuales necesarios para el manejo de la aplicación resultado del desarrollo. Si se ha realizado algún tipo de evaluación de la solución proporcionada, más allá de las pruebas del sistema, también deberá venir recogida en un capítulo separado dentro de esta parte. Pueden consultarse diversos tipos de evaluaciones sobre sistemas de información en [Hevner et al. \(2004\)](#): casos de estudio, análisis estático, análisis dinámico, simulación, experimento controlado, etc.

A. Manual del desarrollador

A continuación se recogen las instrucciones necesarias para evolucionar el software **UniHub**. Este manual está dirigido a los desarrolladores que pretenden extender o modificar el código fuente, con el fin de incorporar nuevas funcionalidades o modificar las ya existentes.

A.1. Introducción

El proyecto **UniHub** está estructurado en 4 fases de código totalmente desacopladas situadas en `d:\Proyecto\Codigo\`: `Crawler/`, `API/`, `WWW/` y `Docker/`.

A.2. Preparación del entorno de trabajo

1. Instalar Python 3.12, Node.js 20+, PostgreSQL 15 y Docker Desktop / Engine.
2. Clonar o abrir la carpeta raíz del repositorio `d:/Proyecto`.
3. Para desarrollo en local sin Docker:
 - Entorno virtual Python del Crawler: `cd Codigo/Crawler; python -m venv .venv; ./.venv/Scripts/activate; pip install -r requirements.txt`.
 - Dependencias de la API: `pip install -r Codigo/API/requirements.txt`.
 - Dependencias Web Frontend: `cd Codigo/WWW; npm install`.

A.3. Consideraciones generales sobre el desarrollo

- **Gestión de Datos no Vacíos y Filtro Estricto:** Cualquier modificación en el crawler debe respetar el filtro estricto de titulaciones vigentes y la función `is_valid_value` de `checkpoint.py` para impedir la sobrescritura accidental de registros válidos.
- **Nuevos Endpoints en la API REST:** Al incorporar nuevos endpoints en FastAPI, defina siempre los esquemas Pydantic correspondientes en `schemas/schemas.py` y añada el router a `main.py`.
- **Sistema de Diseño UCA:** Al añadir componentes visuales en React, utilice las variables CSS corporativas de la UCA (`--uca-navy`, `--uca-blue`, `--uca-cyan`, `--uca-gold`) y la clase `.badge-doctorado` definidas en `src/index.css`.

- **Resiliencia de UI:** Toda ruta pública debe estar protegida por `ErrorBoundary` y componentes pesados deben cargarse con `React.lazy` y `Suspense`. Evitar comparaciones contra datos mock en tiempo de ejecución; usar banderas de estado como `initialDataLoaded` para controlar efectos secundarios.

A.4. Instrucciones para construcción

- **Compilar Frontend (Vite Bundle):** `cd Codigo/WWW; npm run build.`
- **Construir y Levantar Todo con Docker:** `cd Codigo/Docker; docker compose up --build -d.`
- **Ejecutar Carga ETL:** `docker compose exec api python database/etl_loader.py.`

B. Manual de usuario

Las instrucciones de uso del software se detallan a continuación. Este manual se dirige al usuario final del sistema **UniHub**.

B.1. Introducción

El Portal Web de **UniHub** (Fase 3) permite a cualquier usuario consultar el catálogo oficial de universidades de España, explorar sus titulaciones vigentes de Grado, Máster y Doctorado, revisar el desglose de asignaturas y créditos ECTS extraídos del BOE, ajustar la paginación a sus necesidades y localizar los centros más cercanos a su posición actual.

B.2. Instalación

Para acceder al sistema no se requiere ninguna instalación por parte del usuario final. Únicamente se necesita un navegador web moderno (Google Chrome, Mozilla Firefox, Microsoft Edge o Safari) y conexión a la red donde esté desplegado el servicio (<http://localhost> o <http://localhost:5173>).

B.3. Uso del sistema

1. **Exploración de Universidades:** Acceda a la pestaña "Universidades" para filtrar centros públicos (listados prioritariamente en primer lugar) o privados por nombre o comunidad autónoma.
2. **Buscador de Titulaciones y BOE:** En la pestaña "Titulaciones", busque por cualquier titulación o filtre por Grado, Máster o Doctorado. Al hacer clic sobre una tarjeta, se abrirá el modal interactivo con la estructura de créditos ECTS, el listado de asignaturas y el enlace oficial al PDF del BOE.
3. **Paginación Configurable:** En la parte inferior de las grillas de universidades y titulaciones, seleccione el número de elementos a mostrar por página (5, 10, 20, 50 o 100) y navegue entre páginas con los botones de control.
4. **Búsqueda por Cercanía (Geolocalización):** En la pestaña "Por Cercanía", pulse el botón "Usar Mi Ubicación Actual (GPS)" para permitir que el navegador calcule la distancia exacta en km a cada universidad y visualícela directamente dentro de la tarjeta de cada centro.

5. **Sección "Sobre Nosotros":** Acceda a la pestaña "Sobre Nosotros" para consultar la información institucional del proyecto (Trabajo Fin de Grado de Alejandro Ramos Rodríguez en la Universidad de Cádiz).
6. **Panel del Administrador (Acceso Aislado):** Escriba la ruta manual <http://localhost/admin> en la barra de direcciones de su navegador. Ingrese el usuario configurado en VITE_ADMIN_USER y la API Key definida en ADMIN_API_KEY para acceder al panel de administración. No se distribuyen credenciales por defecto.

C. Comandos útiles de latex

Este anexo recopila y define los principales conceptos técnicos, patrones de diseño arquitectónico y acrónimos utilizados a lo largo del desarrollo de la plataforma UniHub.

C.1. Glosario de Conceptos y Patrones de Diseño

AbortController: Interfaz estándar de la API Fetch del navegador que permite abortar y cancelar peticiones HTTP asíncronas en curso. En UniHub se utiliza para cancelar peticiones obsoletas en búsquedas con *debounce* y evitar condiciones de carrera (*race conditions*) en la actualización del estado.

Bulk Save / Bulk Insert: Estrategia de inserción masiva a nivel de ORM (SQLAlchemy) y base de datos que agrupa miles de registros en una única transacción e instrucción SQL compuesta, reduciendo el tiempo de carga ETL de 15 segundos a menos de 1,5 segundos.

Circuit Breaker (Cortocircuito): Patrón de diseño de resiliencia y estabilidad que detecta fallos consecutivos de conexión hacia servidores remotos (RUCT/BOE). Si se superan 10 errores seguidos, abre el circuito pausando el proceso durante 5 minutos para permitir la recuperación del servidor destino, abortando la universidad tras 15 minutos acumulados de caída continuada.

Code Splitting: Técnica de optimización web soportada por Vite y Webpack que divide el bundle de JavaScript en múltiples fragmentos más pequeños que se descargan bajo demanda mediante importaciones dinámicas (*React.lazy*), acelerando el tiempo de carga inicial de la página.

Core Web Vitals (CWV): Conjunto de métricas estandarizadas por Google (LCP, INP, CLS) para cuantificar la experiencia del usuario en términos de velocidad de renderizado, interactividad y estabilidad visual.

ErrorBoundary: Patrón de componente React que intercepta excepciones JavaScript no controladas en cualquier parte de su subárbol de componentes hijos, registrando el error y mostrando una interfaz gráfica de contingencia sin romper toda la aplicación.

Green IT (Tecnologías de la Información Verdes): Enfoque de ingeniería de software orientado a minimizar la huella de carbono y el consumo energético de la infraestructura computacional. En UniHub se modela a través de la telemetría de procesamiento ($\approx 0,05$ gCO₂/MB) y el aprovechamiento de caché (99,8% de aciertos).

Healthcheck: Mecanismo de sondeo periódico configurado en Docker Compose que monitoriza el estado de operatividad de un contenedor (ej. PostgreSQL respon-

diendo a `pg_isready`) antes de permitir que servicios dependientes (como la API o el Crawler) comiencen a emitir peticiones.

Multi-stage build: Método de construcción de imágenes Docker que utiliza múltiples directivas `FROM` intermedias para compilar dependencias pesadas y copiar únicamente los binarios estáticos finales a una imagen mínima en producción (`alpine`), reduciendo el peso de cientos de megabytes a menos de 25 MB.

Patrón Productor-Consumidor: Arquitectura de concurrencia desacoplada donde un proceso productor (descarga de red multihilo I/O) introduce tareas en una cola thread-safe (`multiprocessing.Queue`) y un conjunto de procesos consumidores (trabajadores CPU) procesan el parseo sintáctico de los PDFs en paralelo.

React.lazy y Suspense: APIs nativas de React para carga perezosa de componentes que permiten diferir la importación de vistas pesadas (como el panel de administración o el simulador financiero) hasta el momento exacto en que el usuario navega a dichas secciones.

Robots Exclusion Protocol (RFC 9309): Estándar web que regula las directivas de acceso de los rastreadores automatizados mediante el archivo `robots.txt` y el parámetro de cortesía `Crawl-delay`.

SQLite WAL (Write-Ahead Logging): Modo de diario transaccional de SQLite implementado en `unihub_cache.sqlite3` que permite lecturas concurrentes instantáneas ($< 0,1$ ms) sin ser bloqueadas por operaciones de escritura simultáneas.

UseMemo y useCallback: Ganchos (*hooks*) de optimización en React que memorizan cálculos computacionalmente pesados y referencias de funciones para prevenir re-renderizados innecesarios del árbol del DOM.